



Universidad Internacional de la Rioja (UNIR)

Escuela Superior de Ingeniería y
Tecnología

Máster en Inteligencia Artificial

Segmentación Semántica
para Detección Asistida
de Melanoma con
Cálculo Automático
de Métricas ABCD

Trabajo Fin de Estudios

presentado por: Salvador Pérez Lago

Dirigido por: Alexandre Pérez Reina

Ciudad: Logroño

Fecha: Febrero de 2025

Índice de Contenidos

Resumen	VII
Abstract	VIII
1. Introducción	1
1.1. Contexto y motivación	1
1.2. Problema de investigación	2
1.3. Objetivos del trabajo	3
1.3.1. Objetivo principal	3
1.3.2. Objetivos específicos	4
1.4. Estructura del documento	4
2. Estado del Arte	7
2.1. Introducción al diagnóstico dermatológico asistido por computadora	7
2.2. Segmentación semántica en imágenes médicas	8
2.3. Arquitecturas de segmentación semántica	10
2.3.1. Arquitecturas basadas en U-Net	10
2.3.2. Arquitecturas basadas en Dilated Convolutions	14
2.3.3. Arquitecturas Transformer-CNN híbridas	16
2.4. Funciones de pérdida en segmentación médica	17
2.4.1. Pérdidas basadas en regiones	18
2.4.2. Pérdidas combinadas	19
2.5. Técnicas de entrenamiento	19
2.5.1. Learning Rate Warmup	20
2.5.2. Early Stopping	20
2.6. Métricas ABCD en diagnóstico dermatológico	21
2.6.1. Asimetría (A)	22
2.6.2. Bordes (B)	22
2.6.3. Color (C)	23
2.6.4. Diferenciación estructural (D)	23
2.7. Conjunto de datos ISIC (International Skin Imaging Collaboration)	24
2.8. Limitaciones actuales y brechas de investigación	25

3. Metodología	26
3.1. Introducción	26
3.2. Análisis exploratorio del conjunto datos (EDA)	26
3.2.1. Variabilidad en dimensiones y relación de aspecto	27
3.2.2. Heterogeneidad en las distribuciones de intensidad de píxeles	27
3.2.3. Análisis de la cobertura y morfología de las lesiones	28
3.2.4. Calidad de máscaras	28
3.3. Preprocesamiento y aumento de datos	30
3.3.1. Pipeline de preprocesamiento	30
3.3.2. Estrategias de aumento de datos	32
3.3.3. Manejo del desbalance de clases	33
3.4. Arquitecturas de segmentación implementadas	34
3.4.1. U-Net Básica	34
3.4.2. Attention U-Net	35
3.4.3. Residual U-Net	35
3.4.4. U-Net++	36
3.4.5. DeepLabV3+	36
3.4.6. TransUNet	36
3.5. Configuración experimental	37
3.5.1. Entorno computacional	37
3.5.2. Hiperparámetros y configuración de entrenamiento	38
3.5.3. Funciones de pérdida	39
3.5.4. Técnicas de entrenamiento	39
3.5.5. Optimizador	40
3.6. Métricas de evaluación	41
3.6.1. Métricas por píxel	41
3.6.2. Métricas por imagen y análisis de variabilidad	42
3.7. Desarrollo de la aplicación web	43
3.7.1. Arquitectura del sistema	43
3.7.2. Implementación del cálculo de métricas ABCD	44
4. Resultados experimentales	48
4.1. Entrenamiento y convergencia de modelos	48

4.2.	Evaluación cuantitativa en el conjunto de prueba	49
4.3.	Análisis estadístico comparativo	51
4.4.	Análisis cualitativo y visualización	51
4.5.	Curvas ROC y análisis de calibración	53
4.6.	Análisis de eficiencia computacional	55
4.7.	Resumen de resultados	56
4.8.	Demostración de la aplicación web para inferencia y cálculo ABCD	57
4.8.1.	Arquitectura y funcionalidades principales	57
4.8.2.	Flujo de trabajo del usuario	58
4.8.3.	Ejemplo práctico de análisis ABCD	59
5.	Conclusiones y trabajo futuro	60
5.1.	Conclusiones	60
5.2.	Limitaciones del estudio	61
5.3.	Trabajo futuro	62
5.3.1.	Mejoras metodológicas y técnicas	62
5.3.2.	Extensiones clínicas y de aplicación	63
	Referencias	64
A.	Resumen del código	69
A.1.	Requisitos del sistema	69
A.1.1.	Prerrequisitos	69
A.1.2.	Instalación del entorno	69
A.1.3.	Dataset ISIC 2018	69
A.2.	Estructura de directorios	70
A.3.	Descripción de componentes principales	71
A.3.1.	Módulo de datos (<code>src/data_preparation/</code>)	71
A.3.2.	Módulo de modelos (<code>src/models/</code>)	72
A.3.3.	Notebooks experimentales (<code>notebooks/</code>)	73
A.4.	Reproducción de experimentos	73
B.	Manual de usuario de la app	74
B.1.	Instalación y ejecución	74
B.1.1.	Requisitos	74

B.1.2.	Ejecución del servidor	74
B.1.3.	Script de ejecución	74
B.2.	API REST	75
B.2.1.	Endpoints de salud e información del sistema	75
B.2.2.	Endpoints de gestión de pacientes	75
B.2.3.	Endpoint de predicción	75
B.3.	Flujo de trabajo del usuario	76
B.3.1.	Paso 1: Gestión de pacientes	76
B.3.2.	Paso 2: Subida de imagen	76
B.3.3.	Paso 3: Selección de modelo	76
B.3.4.	Paso 4: Análisis	76
B.3.5.	Paso 5: Visualización de resultados	76
B.3.6.	Paso 6: Historial	77
B.4.	Estructura de la aplicación	77

Índice de Ilustraciones

2.1. Arquitectura U-Net original	11
2.2. Arquitectura de Attention U-Net	12
2.3. Mecanismo de atención en Attention U-Net	13
2.4. Arquitectura DeepLabV3+	15
2.5. Arquitectura TransUNet	17
3.1. Distribución de características en los conjuntos de entrenamiento, validación y prueba	29
4.1. Resultados de Dice Score e IoU en el conjunto de prueba	50
4.2. Comparación cualitativa estructurada de segmentaciones para los seis mo- delos evaluados. Para cada uno de los tres casos clínicos representativos se muestran: la imagen dermatoscópica original, la máscara de referencia (Ground Truth), y las máscaras segmentadas por U-Net Básica, Attention U-Net, Residual U-Net, U-Net++, DeepLabV3+, y TransUNet. Cada pre- dicción incluye su correspondiente Dice Score, permitiendo una evaluación visual y cuantitativa simultánea.	52
4.3. Curvas ROC comparativas para los seis modelos evaluados. El área bajo la curva (AUC) mide la capacidad discriminativa global. Todas las arquitec- turas muestran un excelente desempeño ($AUC > 0.95$), con DeepLabV3+ alcanzando el valor más alto.	54
4.4. Interfaz de la aplicación web mostrando los módulos de gestión de pacientes, selección de modelo y subida de imagen.	58
4.5. Ejemplo de análisis ABCD completo. La lesión presenta asimetría moderada (0.28), bordes poco irregulares, 5 colores significativos incluyendo rojo y diámetro de 20.26 mm, resultando en una puntuación de riesgo medio de 4.6/10.	59

Índice de Tablas

3.1. Distribución del conjunto de datos ISIC 2018	26
3.2. Transformaciones de aumento de datos aplicadas	33
3.3. Configuración del entorno computacional	38
3.4. Configuración de hiperparámetros por arquitectura	38
3.5. Métricas de evaluación implementadas	42
4.1. Resumen del proceso de entrenamiento de los modelos	48
4.2. Resultados de evaluación en el conjunto de prueba ($n = 1,000$ imágenes) . .	49
4.3. Estadísticas detalladas de la distribución de Dice Scores por modelo	51
4.4. Análisis de eficiencia computacional en inferencia (tamaño de entrada: 256x256)	55
4.5. Resumen de rendimiento y eficiencia para la selección de modelos	56
A.1. Contenido del dataset ISIC 2018	70

Resumen

Este trabajo desarrolla un sistema de diagnóstico asistido por computadora (CAD) para la detección temprana de melanoma mediante técnicas de inteligencia artificial. Se realiza una evaluación comparativa exhaustiva de seis arquitecturas avanzadas de segmentación semántica (U-Net, Attention U-Net, Residual U-Net, U-Net++, DeepLabV3+ y TransUNet) sobre el dataset dermatológico ISIC 2018. La metodología implementa un pipeline completo que incluye preprocesamiento de imágenes, aumento de datos específico para dermatoscopia, optimización con funciones de pérdida combinadas (BCE + Dice) y técnicas de entrenamiento como *early stopping* y learning rate warmup. Adicionalmente, se implementa y evalúa una **aplicación web** que combina inferencia en tiempo real con los modelos entrenados y el cálculo automático de métricas clínicas ABCD (Asimetría, Bordes, Color, Diferenciación).

Palabras clave: Segmentación semántica, melanoma, diagnóstico asistido por computadora, visión por computador, aprendizaje profundo, métricas ABCD.

Abstract

Title: Semantic Segmentation for Computer-Aided Melanoma Detection with Automatic ABCD Metrics Calculation

This work addresses the development of a computer-aided diagnosis (CAD) system for early melanoma detection using artificial intelligence techniques. An exhaustive comparative evaluation of six advanced semantic segmentation architectures (U-Net, Attention U-Net, Residual U-Net, U-Net++, DeepLabV3+, and TransUNet) is conducted on the ISIC 2018 dermatological dataset. The methodology implements a complete pipeline including image preprocessing, dermatoscopy-specific data augmentation, optimization with combined loss functions (BCE + Dice), and advanced training techniques such as mixed precision training and learning rate warmup. Additionally, a web application is implemented and evaluated, combining real-time inference with trained models and automatic calculation of clinical ABCD metrics (Asymmetry, Border, Color, Dermoscopic structures).

Keywords: Semantic segmentation, melanoma, computer-aided diagnosis, computer vision, deep learning, ABCD metrics.

1. Introducción

Este capítulo establece los fundamentos de la investigación. Se contextualiza el melanoma cutáneo como un problema de salud pública creciente, donde el diagnóstico temprano es crucial. Se presenta la dermatoscopia como herramienta clave, pero con limitaciones que la inteligencia artificial puede ayudar a superar. Partiendo de este escenario, se define el problema central: los desafíos específicos de la segmentación semántica de lesiones en imágenes dermatoscópicas. Finalmente, se explicitan los objetivos del trabajo y se describe la estructura del documento.

1.1. Contexto y motivación

El melanoma cutáneo representa uno de los tipos de cáncer de piel más agresivos, siendo responsable de aproximadamente el 75 % de las muertes relacionadas con cáncer cutáneo a nivel mundial (Schadendorf y cols., 2018). Su incidencia global ha experimentado un incremento sostenido en las últimas décadas, con tasas que se han triplicado desde la década de 1970 en poblaciones de origen europeo (Arnold y cols., 2022). Esta tendencia ascendente convierte al melanoma en un problema de salud pública de primer orden, especialmente en regiones con alta exposición solar y poblaciones de fototipos claros.

El diagnóstico temprano constituye el factor pronóstico más determinante en la evolución de esta enfermedad. Cuando se detecta en estadios iniciales, la supervivencia a 5 años supera el 98 %, mientras que desciende drásticamente a menos del 25 % en casos metastásicos (Gershenwald y cols., 2017). Esta disparidad pronóstica subraya la importancia crítica de identificar las lesiones sospechosas en sus fases más tempranas, cuando las características clínicas pueden ser sutiles y difíciles de diferenciar de lesiones benignas.

La dermatoscopia (también conocida como epiluminiscencia o microscopía de superficie) revolucionó el diagnóstico dermatológico al permitir la visualización de estructuras subepidérmicas no perceptibles a simple vista (Kittler, Pehamberger, Wolff, y Binder, 2002). Sin embargo, esta técnica presenta limitaciones inherentes: depende considerablemente de la experiencia y entrenamiento del especialista, muestra variabilidad interobservador significativa y enfrenta desafíos particulares en la evaluación de lesiones atípicas o

en estadios iniciales (Vestergaard, Macaskill, Holt, y Menzies, 2010). Estas limitaciones se ven exacerbadas en entornos con recursos limitados o en sistemas de salud con alta presión asistencial, donde el tiempo de evaluación por paciente es limitado.

En este contexto, la inteligencia artificial (IA) y específicamente el aprendizaje profundo (*deep learning*) han emergido como tecnologías transformadoras en el ámbito de la imagen médica. Los sistemas de diagnóstico asistido por computadora (*Computer-Aided Diagnosis*, CAD) basados en redes neuronales convolucionales han demostrado un rendimiento comparable e incluso superior al de dermatólogos expertos en tareas de clasificación de lesiones cutáneas (Esteva y cols., 2017; Tschandl y cols., 2020). No obstante, la mayoría de estos avances se han concentrado en la clasificación binaria (benigno versus maligno), relegando a un segundo plano la segmentación precisa de las lesiones, etapa fundamental para el análisis cuantitativo de características morfológicas y la obtención de métricas clínicamente relevantes.

1.2. Problema de investigación

La segmentación semántica de lesiones melanocíticas en imágenes dermatoscópicas representa un desafío computacional de considerable complejidad, derivado de factores intrínsecos tanto a las características de las imágenes médicas como a la naturaleza biológica de las propias lesiones:

1. **Variabilidad morfológica extrema:** Las lesiones presentan una diversidad morfológica considerable que abarca desde formas regulares y simétricas hasta configuraciones altamente irregulares y asimétricas. Esta variabilidad incluye diferencias significativas en tamaño, contorno, textura y patrones de pigmentación (Menzies, 2009).
2. **Artefactos y condiciones de adquisición:** Las imágenes dermatoscópicas frecuentemente contienen artefactos como pelos, burbujas de aire, reflejos especulares, marcas de regla dermatológica y sombras, que pueden confundir a los algoritmos de segmentación (Barata, Celebi, y Marques, 2019). Además, las variaciones en iluminación, distancia focal y presión de contacto afectan la calidad y consistencia de las imágenes.

3. **Bajo contraste y bordes difusos:** En muchos casos, particularmente en lesiones incipientes o en fototipos de piel oscura, la transición entre la lesión y la piel circundante es gradual y sutil, presentando una zona de difuminado que dificulta la delimitación precisa de los bordes (Oliveira y cols., 2016).
4. **Desbalance de clases significativo:** El área ocupada por la lesión típicamente representa una fracción minoritaria de la imagen completa (generalmente entre el 5 % y el 30 % de los píxeles), generando un desbalance marcado entre la clase de interés (lesión) y la clase mayoritaria (fondo) (Salehi, Erdogmus, y Gholipour, 2017).
5. **Necesidad de integración en flujos clínicos:** Los sistemas de segmentación deben proporcionar no solo máscaras precisas, sino también métricas cuantitativas que sean clínicamente interpretables y que puedan integrarse de manera fluida en los procesos de decisión diagnóstica (Marchetti y cols., 2020).

A pesar del notable progreso en arquitecturas de segmentación semántica durante la última década, persiste la necesidad de evaluaciones comparativas rigurosas que determinen qué aproximaciones arquitectónicas son más adecuadas para este dominio específico. Dicha evaluación debe considerar no solo el rendimiento métrico tradicional, sino también aspectos como la eficiencia computacional, la capacidad de generalización a distintos tipos de lesiones y la robustez frente a variaciones en las condiciones de adquisición.

1.3. Objetivos del trabajo

Este trabajo de fin de máster se articula en torno a un objetivo principal de naturaleza comparativa, complementado con un componente aplicado que busca validar la utilidad práctica de los modelos en un contexto clínico simulado.

1.3.1. Objetivo principal

Realizar una evaluación comparativa exhaustiva de seis arquitecturas avanzadas de segmentación semántica aplicadas a la delimitación precisa de lesiones melanocíticas en imágenes dermatoscópicas, determinando cuál ofrece el mejor compromiso entre precisión métrica, robustez frente a variaciones morfológicas y eficiencia computacional.

1.3.2. Objetivos específicos

1. **Caracterización exhaustiva del conjunto de datos:** Realizar un análisis exploratorio completo del dataset ISIC 2018, cuantificando distribuciones de tamaño, intensidad, cobertura de lesión y verificando la consistencia entre los subconjuntos de entrenamiento, validación y prueba.
2. **Implementación y configuración sistemática:** Implementar seis arquitecturas representativas del estado del arte en segmentación médica: U-Net clásica, Attention U-Net, Residual U-Net, U-Net++, DeepLabV3+ y TransUNet, configurando hiperparámetros específicos para cada arquitectura según mejores prácticas reportadas en la literatura.
3. **Optimización metodológica:** Aplicar y evaluar técnicas de entrenamiento incluyendo *learning rate warmup*, schedulers o *early stopping* controlado por métricas de validación.
4. **Evaluación cuantitativa multicriterio:** Comparar los modelos utilizando un conjunto comprehensivo de métricas de segmentación (Dice Score, IoU, precisión, recall, exactitud) y analizar sus curvas de aprendizaje, tiempos de convergencia, consumo de memoria y estabilidad durante el entrenamiento.
5. **Desarrollo de aplicación integrada:** Implementar una aplicación web interactiva que permita la inferencia en tiempo real con los modelos entrenados y el cálculo automático de métricas dermatoscópicas ABCD (Asimetría, Bordes, Color, Diferenciación) a partir de las máscaras segmentadas.

1.4. Estructura del documento

Este documento se estructura en 5 capítulos y 2 apéndices que guían al lector desde los fundamentos teóricos y el contexto clínico hasta los resultados experimentales, la aplicación práctica y las conclusiones finales:

- **Capítulo 1 (Introducción):** Establece el marco de la investigación, contextualizando el problema del melanoma cutáneo, las limitaciones del diagnóstico dermatoscópico convencional y el potencial de la inteligencia artificial. Define claramente el

problema de investigación, los objetivos generales y específicos del trabajo y presenta la estructura del documento.

- **Capítulo 2 (Estado del arte):** Revisa los antecedentes científicos en segmentación de imágenes médicas, arquitecturas de redes neuronales aplicadas a dermatología, técnicas de evaluación de modelos y el sistema de puntuación ABCD en diagnóstico dermatológico.
- **Capítulo 3 (Metodología):** Describe de manera sistemática y reproducible el diseño experimental completo, detallando el análisis exploratorio del conjunto de datos (EDA), el pipeline de preprocesamiento y aumento de datos, las seis arquitecturas de segmentación implementadas, la configuración de hiperparámetros y técnicas de entrenamiento, las métricas de evaluación utilizadas y el desarrollo de la aplicación web para inferencia y cálculo ABCD.
- **Capítulo 4 (Resultados experimentales):** Presenta y analiza de forma estructurada los hallazgos del estudio comparativo. Incluye los resultados del entrenamiento y convergencia, la evaluación cuantitativa multicriterio en el conjunto de prueba, el análisis estadístico comparativo, la evaluación cualitativa, el análisis de eficiencia computacional y una demostración de la funcionalidad de la aplicación web desarrollada
- **Capítulo 5 (Conclusiones y trabajo futuro):** Sintetiza las principales conclusiones derivadas de los resultados, discute los compromisos (trade-offs) identificados entre las arquitecturas y sus implicaciones prácticas. Reconoce las limitaciones del estudio actual y propone direcciones concretas para futuras investigaciones, tanto en mejoras metodológicas como en extensiones clínicas e implementaciones técnicas.
- **(Apéndice A):** Documenta la estructura del código del proyecto, los requisitos de instalación y las instrucciones para replicar los experimentos.
- **(Apéndice B):** Proporciona un manual de usuario para la aplicación web de segmentación y cálculo ABCD.

Este trabajo se enmarca en la tipología «**Comparativa de soluciones**», con un componente adicional de desarrollo aplicado que acerca los resultados de investigación a un

contexto de utilidad clínica potencial. La investigación combina así un análisis comparativo riguroso de aproximaciones técnicas con el desarrollo de una herramienta práctica que valida la transferibilidad de los modelos a escenarios de uso real.

2. Estado del Arte

Este capítulo revisa el estado del arte en las áreas que convergen en este trabajo. Comienza trazando la evolución del diagnóstico dermatológico asistido por computadora hacia el aprendizaje profundo. A continuación, se analizan las arquitecturas de segmentación semántica más relevantes, sus principios y aplicación en dermatología. También se revisan los componentes metodológicos clave: funciones de pérdida adaptadas al desbalance de clases y técnicas de entrenamiento avanzadas. Se explica el sistema de puntuación ABCD y su cuantificación automática y se presenta el conjunto de datos utilizado. El capítulo concluye identificando las limitaciones actuales en el campo, que justifican el enfoque comparativo y aplicado de este estudio.

2.1. Introducción al diagnóstico dermatológico asistido por computadora

El diagnóstico dermatológico asistido por computadora (CAD, por sus siglas en inglés) ha experimentado una evolución significativa en las últimas décadas, evolucionando desde sistemas basados en reglas heurísticas hasta arquitecturas de aprendizaje profundo de última generación. Esta evolución ha estado impulsada por tres factores principales: la disponibilidad creciente de conjuntos de datos dermatológicos anotados, el avance en hardware computacional y el desarrollo de algoritmos de aprendizaje automático más sofisticados (Barata y cols., 2019).

La dermatoscopia, introducida en la década de 1990, marcó un punto de inflexión al permitir la visualización de estructuras epidérmicas y dérmicas superficiales no visibles a simple vista. Esta técnica incrementó la sensibilidad diagnóstica del melanoma de aproximadamente un 60 % con examen clínico convencional a más del 90 % cuando es realizada por expertos (Kittler y cols., 2002). Sin embargo, la interpretación dermatoscópica requiere entrenamiento especializado y presenta una curva de aprendizaje pronunciada, lo que motivó la búsqueda de métodos de apoyo objetivo.

Los primeros sistemas CAD en dermatología se basaron en el análisis de características de bajo nivel extraídas manualmente, como asimetría, irregularidad de bordes, variabili-

dad de color y textura (Celebi y cols., 2007). Estos sistemas, aunque pioneros, presentaban limitaciones significativas en términos de generalización y robustez ya que las características diseñadas manualmente no capturaban adecuadamente la complejidad y variabilidad de las lesiones cutáneas.

La revolución del aprendizaje profundo, particularmente tras el éxito de AlexNet en 2012 (Krizhevsky, Sutskever, y Hinton, 2012), transformó radicalmente el campo. Las redes neuronales convolucionales (CNN) demostraron una capacidad superior para aprender representaciones jerárquicas de características directamente de los datos, superando significativamente a los métodos tradicionales en múltiples tareas de visión por computadora (Litjens y cols., 2017).

2.2. Segmentación semántica en imágenes médicas

La segmentación semántica en imágenes médicas consiste en la asignación de una etiqueta de clase a cada píxel de una imagen, diferenciando entre estructuras anatómicas de interés y el fondo. En el contexto dermatológico, esto se traduce en la delimitación precisa de los bordes de las lesiones cutáneas. Esta tarea presenta desafíos particulares que la diferencian de la segmentación en dominios naturales:

1. **Bordes difusos y transiciones graduales:** Muchas estructuras médicas, incluidas las lesiones cutáneas, presentan límites mal definidos donde la intensidad o textura cambia gradualmente, en contraste con los bordes nítidos típicos de objetos en imágenes naturales (Ronneberger, Fischer, y Brox, 2015).
2. **Variabilidad inter e intra-paciente:** Las características de las lesiones varían significativamente entre diferentes pacientes e incluso en el mismo paciente a lo largo del tiempo, debido a factores como fototipo, localización anatómica y estadio de evolución (Tschandl, Rosendahl, y Kittler, 2018).
3. **Artefactos de adquisición:** Las imágenes médicas frecuentemente contienen artefactos específicos del dominio, como marcas de regla dermatológica, reflejos especulares, sombras y obstrucciones por vello, que requieren estrategias de preprocesamiento especializadas (González-Díaz, 2017).

4. **Anotación costosa y subjetiva:** La creación de máscaras de segmentación ground truth requiere la intervención de expertos médicos, es un proceso laborioso y costoso y puede presentar variabilidad interobservador significativa (Codella y cols., 2018).
5. **Desbalance de clases extremo:** En muchos casos, la estructura de interés ocupa solo una pequeña fracción de la imagen total, lo que plantea desafíos para el entrenamiento de modelos y la evaluación de su rendimiento (Milletari, Navab, y Ahmadi, 2016).

Desde el punto de vista de la evaluación cuantitativa, los modelos de segmentación médica requieren métricas específicas que capturen diferentes aspectos del rendimiento:

- **Dice Similarity Coefficient (DSC):** También conocido como coeficiente de Sørensen-Dice, mide la superposición entre la segmentación predicha y la ground truth:

$$DSC = \frac{2|X \cap Y|}{|X| + |Y|}$$

donde X e Y representan los conjuntos de píxeles de la predicción y la verdad de terreno respectivamente. Es particularmente útil en segmentación médica debido a su robustez frente al desbalance de clases (Dice, 1945; Sørensen, 1948).

- **Intersection over Union (IoU o Jaccard Index):** Mide la relación entre el área de superposición y el área de unión:

$$IoU = \frac{|X \cap Y|}{|X \cup Y|}$$

El IoU es más estricto que el DSC y penaliza más severamente las falsas detecciones (Jaccard, 1912).

- **Precisión y Recall:** Miden respectivamente la proporción de predicciones positivas correctas y la proporción de casos positivos reales detectados:

$$Precision = \frac{TP}{TP + FP}$$
$$Recall = \frac{TP}{TP + FN}$$

donde TP son verdaderos positivos, FP son falsos positivos y FN son falsos negativos. En el contexto médico, estas métricas deben interpretarse considerando las implicaciones clínicas de falsos positivos y falsos negativos (Powers, 2020). En caso

de enfermedades de alto riesgo, como los cánceres, se prioriza el Recall para no pasar por alto posibles casos; para casos en los que el diagnóstico puede tener un alto costo/riesgo, se prioriza la Precisión para evitar daños innecesarios.

2.3. Arquitecturas de segmentación semántica

El desarrollo de arquitecturas de segmentación semántica representa uno de los pilares fundamentales para el avance del diagnóstico dermatológico asistido por computadora. Este campo ha experimentado una evolución significativa, transitando desde métodos clásicos basados en características manuales y umbralización adaptativa hacia sofisticados sistemas de aprendizaje profundo capaces de una delineación precisa y automatizada de lesiones cutáneas. Esta transición ha sido impulsada por la necesidad de abordar desafíos intrínsecos al dominio médico, como la alta variabilidad en la apariencia de las lesiones, la presencia de artefactos (*e.g.*, pelos, burbujas, reflejos) y la ambigüedad en la definición de los bordes. La evolución de las arquitecturas puede analizarse a través de varias familias paradigmáticas, cada una de las cuales ha introducido innovaciones conceptuales y técnicas para mejorar la captura de contexto semántico, la preservación de la resolución espacial y la robustez frente a datos limitados, logrando así un impacto directo en la precisión diagnóstica.

2.3.1. Arquitecturas basadas en U-Net

La familia de arquitecturas U-Net, originada en el ámbito de la segmentación biomédica, ha dominado el panorama por su diseño intuitivo y su notable eficacia incluso con conjuntos de datos de entrenamiento reducidos. Su principio central, la combinación simbiótica de un camino contractivo para la extracción de contexto y uno expansivo para la localización precisa mediante conexiones de salto, ha servido como plantilla para numerosas variantes.

U-Net clásica

Propuesta por Ronneberger et al. en 2015 para el desafío de segmentación de células en imágenes de microscopía (Ronneberger y cols., 2015), la U-Net original estableció un nuevo paradigma. Su arquitectura en forma de “U” soluciona elegantemente el dilema fundamental en visión por computadora: las capas profundas de una red capturan características semánticas ricas (el “qué”) pero con una resolución espacial reducida, mientras

que las capas superficiales preservan la información espacial detallada (el “dónde”) pero con una comprensión semántica limitada.

La innovación clave radica en las **conexiones de salto** (*skip connections*), que transportan los mapas de características de alta resolución desde el encoder (camino contractivo) directamente a las capas correspondientes del decoder (camino expansivo). Esta conexión permite al decoder, mientras realiza convoluciones transpuestas para aumentar la resolución, “recordar” la localización precisa de los bordes y texturas que podrían haberse perdido durante el *pooling*.




Figura 2.1: Arquitectura U-Net original propuesta por Ronneberger et al. (2015) (Ronneberger y cols., 2015). Nótese el camino contractivo (izquierda), el camino expansivo (derecha) y las conexiones de salto (flechas horizontales).

Además, la estrategia de aumento de datos mediante transformaciones elásticas, también introducida por los autores, fue crucial para enseñar a la red la invariancia a deformaciones no lineales típicas de los tejidos biológicos, una propiedad que se traslada beneficiosamente a las imágenes de piel. La U-Net clásica demostró que una arquitectura relativamente ligera y bien diseñada podía superar a soluciones más complejas en tareas médicas, sentando las bases para una generación de modelos.

Attention U-Net

Introducida por Oktay et al. en 2018 (Oktay y cols., 2018), Attention U-Net aborda una limitación inherente a las conexiones de salto estándar, que es que éstas combinan de manera indiscriminada toda la información de la capa del encoder, incluyendo regiones de fondo o artefactos irrelevantes para la tarea de segmentación. Para solventar esto, la arquitectura incorpora un **mecanismo de atención gated** (*gated attention*) en cada conexión de salto. Este mecanismo actúa como un filtro espacial adaptativo, aprendido durante el entrenamiento, que genera un mapa de atención (valores entre 0 y 1) para cada localización de la característica del encoder.




Figura 2.2: Arquitectura de Attention U-Net (Oktay y cols., 2018). Los mapas de atención (en rojo) modulan las características antes de la concatenación, permitiendo a la red enfocarse en regiones relevantes.

Matemáticamente, el mapa de atención α^i se calcula a partir de las características del encoder x^i y las características del nivel superior del decoder g , pasando por funciones de activación y transformaciones lineales parametrizadas (W , b). Este mapa modula las características antes de su concatenación, atenuando las respuestas en regiones no relevantes y potenciando aquellas en las regiones de la lesión.

$$\alpha^i = \sigma \left(W_{\alpha}^T \left(\sigma \left(W_x^T x^i + b_x \right) + \sigma \left(W_g^T g + b_g \right) \right) + b_{\alpha} \right)$$

En el contexto dermatológico, este enfoque ha probado ser particularmente valioso. Como demostró Liu et al. (Liu, Mou, Zhu, y Mandal, 2020), la Attention U-Net puede aprender a suprimir de forma efectiva artefactos como vellos, marcas de regla, burbujas de




Figura 2.3: Mecanismo de atención en Attention U-Net (Oktay y cols., 2018).

gel o variaciones de iluminación, que son comunes en las imágenes clínicas y de dermatoscopia, permitiendo que el modelo se concentre en los patrones morfológicos de la propia lesión.

Residual U-Net

Inspirada en el éxito de las redes residuales (ResNet) para el entrenamiento de arquitecturas muy profundas (He, Zhang, Ren, y Sun, 2016), la Residual U-Net incorpora **bloques residuales** en lugar de las capas convolucionales simples. En un bloque residual, la salida se define como:

$$\mathcal{F}(x) + x$$

donde x es la entrada y $\mathcal{F}(x)$ representa el resultado de dos o tres capas convolucionales. Esta conexión identidad permite que el gradiente fluya directamente a través de la red, mitigando el problema del desvanecimiento del gradiente (*vanishing gradient*) y facilitando el entrenamiento de redes con un número mayor de capas.

En la segmentación de piel, una mayor profundidad permite a la red aprender representaciones más abstractas y robustas de los patrones malignos versus benignos. Zhang et al. (Zhang, Liu, y Wang, 2018) demostraron que esta variante superaba a la U-Net convencional, especialmente en la delineación de bordes difusos e irregulares, característicos de melanomas y lesiones atípicas ya que la red más profunda y estable puede integrar mejor el contexto a múltiples escalas para resolver ambigüedades locales.

U-Net++

Propuesta por Zhou et al. en 2018 (Zhou, Siddiquee, Tajbakhsh, y Liang, 2018), U-Net++ es una versión de la arquitectura original pero que propone la sustitución de las conexiones de salto simples por un conjunto denso y anidado de conexiones, creando una estructura en rejilla (*grid-like*) entre el encoder y el decoder. En esta configuración, cada nodo del camino de expansión recibe la entrada de todos los nodos anteriores del camino de contracción de la misma o mayor resolución, a través de una serie de operaciones de convolución y concatenación.

Este diseño logra dos objetivos: primero, proporciona al decoder un conjunto de características multiescala enriquecidas y densamente fusionadas, facilitando una mejor integración de la información semántica y espacial. Segundo, habilita una **supervisión profunda** (*deep supervision*), donde se pueden colocar funciones de pérdida auxiliares en diferentes niveles de la rejilla, guiando el aprendizaje de características a múltiples resoluciones y mejorando la convergencia.

Jafari et al. (Jafari y cols., 2020) aplicaron U-Net++ a la segmentación de lesiones cutáneas, encontrando que su capacidad para capturar y fusionar detalles finos y contexto global de manera eficiente la hacía superior para segmentar lesiones pequeñas, con formas muy irregulares o con texturas heterogéneas.

2.3.2. Arquitecturas basadas en Dilated Convolutions

Mientras que las arquitecturas tipo U-Net logran alta resolución espacial mediante el *downsampling* y posterior *upsampling*, otro enfoque radicalmente diferente busca preservar la resolución a lo largo de toda la red. Las arquitecturas basadas en convoluciones dilatadas (o *atrous*) abordan el problema de capturar contexto semántico a gran escala sin sacrificar la resolución espacial, lo que es crucial para una segmentación de bordes precisos.

DeepLabV3+

Desarrollada por Chen et al. en 2018 (L.-C. Chen, Zhu, Papandreou, Schroff, y Adam, 2018), DeepLabV3+ combina convoluciones dilatadas (*atrous*) con un decoder ligero para lograr segmentación precisa y eficiente. Su componente central es el módulo **ASPP**

(**Atrous Spatial Pyramid Pooling**). En lugar de aplicar *pooling* espacial para aumentar el campo receptivo (y perder información), ASPP aplica en paralelo múltiples convoluciones con diferentes tasas de dilatación (r) sobre el mismo mapa de características de alta resolución.

$$\text{ASPP}(x) = \text{Concat} [\text{Conv}_{r=1}(x), \text{Conv}_{r=6}(x), \text{Conv}_{r=12}(x), \text{Conv}_{r=18}(x), \text{GAP}(x)]$$

Una convolución con dilatación r inserta $r - 1$ ceros entre los pesos del kernel, expandiendo efectivamente su campo receptivo sin aumentar el número de parámetros ni reducir la resolución. Las salidas de estas ramas, que capturan información contextual a escalas diferentes (desde detalles locales hasta contexto global), se concatenan junto con características obtenidas por *Global Average Pooling* (GAP). Posteriormente, un **decoder ligero** refina la segmentación combinando las características ricas en contexto de la salida del ASPP con características de bajo nivel y alta resolución extraídas de las capas iniciales de la red, mejorando así la precisión en los bordes.




Figura 2.4: Arquitectura DeepLabV3+ (L.-C. Chen y cols., 2018). Las convoluciones con diferentes tasas de dilatación capturan contexto a múltiples escalas.

Yang et al. (Yang, Xie, Fan, Jiang, y Liu, 2019) aplicaron DeepLabV3+ a la segmentación dermatoscópica y reportaron un rendimiento superior, particularmente en términos de exactitud en los bordes y robustez frente a variaciones significativas de iluminación y sombras, desafíos comunes en las imágenes de piel no estandarizadas.

2.3.3. Arquitecturas Transformer-CNN híbridas

La más reciente revolución en el campo llega con la adopción de arquitecturas de Transformer, originalmente diseñadas para procesamiento de lenguaje natural. Su capacidad para modelar dependencias de largo alcance a través de mecanismos de auto-atención ofrece un complemento potente a las CNN, que son expertas en extraer patrones locales.

TransUNet

Introducida por Chen et al. en 2021 (J. Chen y cols., 2021), TransUNet es una de las primeras y más influyentes arquitecturas híbridas para segmentación médica. Su encoder es un híbrido: primero, una CNN (como ResNet) extrae mapas de características de la imagen. Estos mapas se dividen luego en secuencias de parches (*patches*) que se aplanan y proyectan en embeddings, los cuales son procesados por un Transformer.

El Transformer, mediante su mecanismo de **atención multi-cabeza**, permite que cada parche (que representa una región de la imagen) “preste atención” a todos los demás parches, capturando así relaciones globales y contextuales que una CNN con su campo receptivo local podría pasar por alto. Por ejemplo, puede aprender que la presencia de cierto patrón en una zona de la imagen está correlacionado con la morfología en otra zona distante.

Finalmente, un decoder basado en CNN toma la secuencia enriquecida de embeddings del Transformer, la reensambla en un arreglo espacial y, utilizando conexiones de salto con la CNN inicial, reconstruye la segmentación a alta resolución.

TransUNet ha establecido nuevos estados del arte en varios benchmarks de segmentación médica, demostrando una capacidad excepcional para manejar estructuras con formas complejas, bordes sutiles y una gran variabilidad de apariencia (J. Chen y cols., 2021). En dermatología, este potencial para integrar información contextual global promete una mejor discriminación entre lesiones que comparten características locales similares pero difieren en su configuración global.




Figura 2.5: Arquitectura TransUNet (J. Chen y cols., 2021), que combina CNN para la extracción de características locales con Transformers para modelar dependencias de largo alcance.

2.4. Funciones de pérdida en segmentación médica

La elección y diseño de la función de pérdida constituye un aspecto fundamental en el entrenamiento de modelos de segmentación médica, donde los requisitos de precisión van más allá de una simple exactitud global de píxeles. En este dominio, los problemas inherentes incluyen un severo desbalance de clases (donde el área de la lesión suele ser una fracción menor del fondo de la imagen) y la necesidad crítica de una delineación precisa en los bordes de estructuras anatómicas o patológicas ya que errores de un solo píxel en el contorno pueden afectar mediciones clínicamente relevantes como la asimetría o la irregularidad del borde.

Las funciones de pérdida tradicionales, como la entropía cruzada, pueden fallar en estos escenarios ya que optimizan para la precisión promedio, ignorando efectivamente las clases minoritarias. Por lo tanto, la investigación se ha centrado en utilizar funciones de pérdida que incorporen directamente prioridades clínicas y características geométricas de las regiones a segmentar, guiando al modelo hacia soluciones más útiles y robustas.

2.4.1. Pérdidas basadas en regiones

Las funciones de pérdida basadas en regiones buscan medir la superposición o divergencia entre la máscara predicha y la verdad fundamental a nivel de toda la región de interés, siendo las más extendidas la Binary Cross-Entropy (BCE) y la Dice Loss.

La Binary Cross-Entropy (BCE) es la función de pérdida fundacional para problemas de clasificación binaria y se extiende de manera natural a la segmentación pixel a pixel. Su formulación mide la divergencia de Kullback-Leibler entre la distribución predicha y la real para cada píxel i :

$$\mathcal{L}_{BCE} = -\frac{1}{N} \sum_{i=1}^N [y_i \log(p_i) + (1 - y_i) \log(1 - p_i)]$$

donde $y_i \in 0, 1$ es la etiqueta verdadera, $p_i \in [0, 1]$ es la probabilidad predicha y N es el número total de píxeles. La principal fortaleza de BCE es que proporciona gradientes suaves y bien comportados en todo el espacio de probabilidad, facilitando la estabilidad durante las fases iniciales del entrenamiento. Sin embargo, su principal debilidad en el contexto médico es su sensibilidad al desbalance de clases: al ser una suma sobre todos los píxeles, la contribución del fondo (clase mayoritaria) puede dominar completamente el gradiente, haciendo que el modelo aprenda a ignorar la lesión para minimizar la pérdida.

La Dice Loss, introducida para tareas de segmentación médica por Milletari et al. en 2016 (Milletari y cols., 2016), se deriva directamente del coeficiente de similitud de Dice (DSC), una métrica de evaluación popular en el campo. Esta pérdida optimiza explícitamente para la superposición entre regiones:

$$\mathcal{L}_{Dice} = 1 - \frac{2 \sum_{i=1}^N p_i y_i + \epsilon}{\sum_{i=1}^N p_i + \sum_{i=1}^N y_i + \epsilon}$$

El término ϵ es un pequeño valor de suavizado (e.g., 1×10^{-6}) añadido para estabilidad numérica y evitar divisiones por cero. La pérdida de Dice es intrínsecamente robusta al desbalance de clases porque se normaliza por el tamaño de las regiones; esencialmente, mide la superposición relativa en lugar de los aciertos absolutos. Su desventaja es que puede presentar gradientes inestables cuando tanto la predicción como la verdad fundamental son muy pequeñas, lo que puede ralentizar la convergencia en las primeras épocas. En

dermatología, donde las lesiones pueden ser muy pequeñas en relación con la imagen, la robustez de Dice Loss al desbalance la hace casi indispensable.

2.4.2. Pérdidas combinadas

Dada la naturaleza complementaria de las fortalezas y debilidades de BCE y Dice Loss, la práctica estándar en segmentación médica moderna ha convergido en el uso de funciones de pérdida combinadas. La combinación más simple y extendida es la suma ponderada de la pérdida de entropía cruzada binaria y la pérdida de Dice:

$$\mathcal{L}_{Combined} = \lambda_{BCE} \mathcal{L}_{BCE} + \lambda_{Dice} \mathcal{L}_{Dice}$$

donde λ_{BCE} y λ_{Dice} son hiperparámetros que balancean las contribuciones, siendo común utilizar $\lambda_{BCE} = \lambda_{Dice} = 0,5$ o ajustarlos mediante validación cruzada. Como señalan Isensee et al. (Isensee, Jaeger, Kohl, Petersen, y Maier-Hein, 2021), esta combinación ofrece el mejor de ambos mundos: la entropía cruzada proporciona gradientes suaves y estables desde el inicio del entrenamiento, guiando al modelo lejos de predicciones triviales, mientras que la pérdida de Dice focaliza progresivamente la optimización en la superposición precisa de la región de interés, mitigando el efecto del desbalance de clases. Esta sinergia ha demostrado de manera consistente producir modelos más robustos y con mejor generalización en una amplia gama de tareas de segmentación biomédica, incluyendo la delineación de lesiones cutáneas.

2.5. Técnicas de entrenamiento

El desempeño final de un modelo de aprendizaje profundo no depende únicamente de su arquitectura o función de pérdida, sino también de las estrategias empleadas durante el proceso de optimización. En el dominio de la segmentación médica, donde los conjuntos de datos suelen ser pequeños y los modelos complejos, técnicas avanzadas de entrenamiento son cruciales para lograr una convergencia estable, evitar el sobreajuste y maximizar el potencial representacional de la red.

2.5.1. Learning Rate Warmup

El Learning Rate Warmup es una técnica de programación de la tasa de aprendizaje (*learning rate scheduling*) que consiste en incrementar la tasa de aprendizaje de manera lineal o gradual desde un valor muy bajo (cercano a cero) hasta la tasa de aprendizaje base deseada, durante un número inicial de épocas o iteraciones. Matemáticamente, para un warmup lineal sobre T_{warmup} pasos, la tasa de aprendizaje en el paso t se calcula como:

$$lr_{epoch} = lr_{base} \times \min\left(1, \frac{epoch}{warmup_epochs}\right)$$

La justificación de esta estrategia, popularizada en el entrenamiento de Transformers y adoptada ampliamente en CNNs, es doble. Primero, permite que los estadísticos de las capas de normalización por lotes (BatchNorm) se estabilicen durante las primeras iteraciones, cuando los gradientes son grandes y erráticos, previniendo desviaciones que podrían llevar a una inestabilidad temprana. Segundo, proporciona un período de “calentamiento” donde los parámetros del modelo se ajustan suavemente hacia una región favorable del espacio de pérdidas, evitando cambios bruscos que podrían causar divergencia.

Esta técnica es particularmente efectiva y casi estándar cuando se utiliza con optimizadores adaptativos como Adam o AdamW (Loshchilov y Hutter, 2017), los cuales normalizan las actualizaciones de parámetros usando estimaciones de primer y segundo momento que pueden ser sesgadas al inicio. En el contexto de segmentación dermatológica, donde los modelos suelen ser inicializados con pesos preentrenados en conjuntos de datos naturales (e.g., ImageNet), el warmup permite una transición más suave hacia la distribución específica de las imágenes médicas.

2.5.2. Early Stopping

La técnica de Early Stopping es un método clásico y efectivo de regularización para prevenir el sobreajuste (*overfitting*). Su premisa es simple: monitorear continuamente el rendimiento del modelo en un conjunto de validación independiente durante el entrenamiento y detener el proceso de optimización cuando dicho rendimiento deja de mejorar. La implementación práctica implica definir una métrica de monitorización (generalmente la pérdida de validación o el Dice Score) y un parámetro de paciencia (*patience*), que especifica el número de épocas consecutivas que se permite que la métrica no mejore antes

de detener el entrenamiento. Al final, se restauran los pesos del modelo de la época en la que se obtuvo el mejor valor de la métrica monitorizada.

La efectividad del Early Stopping radica en que detecta el punto donde el modelo comienza a memorizar ruido o patrones específicos del conjunto de entrenamiento que no generalizan a datos nuevos, lo que se manifiesta como una divergencia entre la pérdida de entrenamiento (que sigue disminuyendo) y la pérdida de validación (que se estanca o aumenta). Esta técnica es especialmente valiosa en aplicaciones médicas como la dermatología, donde los conjuntos de datos públicos anotados (como ISIC) son limitados en tamaño y existe un alto riesgo de sobreajuste. A diferencia de la regularización L1/L2 que penaliza la magnitud de los pesos, Early Stopping actúa como un procedimiento de selección del modelo implícito, escogiendo el punto óptimo de generalización en la curva de aprendizaje. Como señala Prechelt (Prechelt, 1998), su principal ventaja es que no interfiere con el proceso de optimización en sí y es computacionalmente barato, requiriendo solo la evaluación periódica en el conjunto de validación.

2.6. Métricas ABCD en diagnóstico dermatológico

El sistema ABCD es un método semiológico estandarizado para la evaluación clínica de lesiones pigmentadas, originalmente propuesto por Friedman et al. en 1985 para la evaluación clínica a simple vista (Friedman, Rigel, y Kopf, 1985), fue posteriormente adaptado y refinado por Nachbar et al. en 1994 para incorporar las observaciones dermatoscópicas, aumentando significativamente su precisión diagnóstica (Nachbar y cols., 1994). Este acrónimo mnemotécnico desglosa la evaluación en cuatro criterios claves—Asimetría, Bordes, Color y Diferenciación estructural—cada uno de los cuales aporta evidencia incremental sobre la probabilidad de malignidad. La fortaleza del sistema radica en su capacidad para cuantificar y sistematizar observaciones subjetivas, transformándolas en una puntuación total (TDS, Total Dermoscopy Score) que guía la toma de decisiones clínicas. La automatización de este análisis mediante visión por computadora no solo busca replicar la evaluación experta, sino también extraer medidas cuantitativas más finas y reproducibles, libres de la variabilidad interobservador que afecta incluso a los dermatólogos experimentados.

2.6.1. Asimetría (A)

El criterio de asimetría se basa en el principio de que las lesiones benignas, como los nevus melanocíticos, tienden a crecer de forma simétrica y radial, mientras que los melanomas suelen exhibir un crecimiento caótico y asimétrico. En la evaluación dermatoscópica estandarizada, la asimetría se evalúa a lo largo de dos ejes perpendiculares que atraviesan el centro de la lesión. Se asigna una puntuación de 0 si la lesión es simétrica en ambos ejes, 1 si es asimétrica en un solo eje y 2 si es asimétrica en ambos ejes. Los métodos computacionales abordan esta cuantificación de manera más rigurosa. Una técnica común implica el análisis de momentos de inercia o la descomposición en componentes principales (PCA) de la máscara binaria de la lesión. Tras la segmentación, se calcula la elipse de mejor ajuste. La asimetría puede entonces medirse mediante la relación entre los ejes mayor y menor de esta elipse, o analizando la distribución de la pigmentación o textura entre los cuadrantes definidos por los ejes principales. Clawson et al. (Clawson, Morrow, Scotney, McKenna, y Dolan, 2009) demostraron cómo estos enfoques geométricos pueden correlacionarse fuertemente con las evaluaciones clínicas de asimetría, proporcionando una medida continua y objetiva en lugar de una puntuación categórica discreta.

2.6.2. Bordes (B)

La evaluación de los bordes se centra en la regularidad del contorno. Los márgenes bien definidos, suaves y circulares son típicos de lesiones benignas, mientras que los bordes irregulares, angulados, festoneados o con escotaduras (muescas) son un marcador de crecimiento radial irregular asociado a la malignidad. La cuantificación computacional de este criterio emplea diversas métricas geométricas derivadas de la máscara de segmentación. La circularidad (o índice de forma), definida como $C = 4\pi A/P^2$, donde A es el área y P el perímetro, es una medida básica: un círculo perfecto tiene $C = 1$ y valores decrecientes indican mayor irregularidad. La compacidad (P^2/A) es una medida similar. Métodos más sofisticados utilizan el análisis de Fourier del contorno: el perímetro de la lesión se describe como una señal unidimensional en función del ángulo y su descomposición en frecuencia revela la contribución de componentes de alta frecuencia (ruidosos), que corresponden a irregularidades finas y muescas. Un perímetro suave se caracteriza por un espectro dominado por bajas frecuencias. Estas métricas permiten discriminar no solo entre bordes regulares e irregulares, sino también caracterizar el tipo específico de irregularidad.

2.6.3. Color (C)

La presencia de múltiples colores y su distribución heterogénea es uno de los signos más sensibles para el melanoma. La regla de los seis colores de Menzies et al. (Menzies, Ingvar, Crotty, y McCarthy, 1996) establece que la presencia de tres o más de los siguientes colores en una lesión es altamente sugestiva de melanoma: blanco, rojo, marrón claro, marrón oscuro, azul-gris y negro. La evaluación automática del color requiere un procesamiento cuidadoso. Primero, es crucial la normalización del color para mitigar variaciones debidas a iluminación, cámara o tono de piel. Luego, el análisis se realiza típicamente en un espacio de color perceptualmente uniforme como CIELAB. Las técnicas incluyen:

1. Cuantificación del número de colores mediante clustering (e.g., k-means) en el espacio de color para identificar los colores dominantes presentes;
2. Análisis de la distribución espacial, evaluando si los colores están distribuidos de manera ordenada (como en los nevus) o caótica y multifocal;
3. Análisis de transiciones cromáticas, midiendo la suavidad o brusquedad de los cambios de color a través de la lesión.

La capacidad de detectar matices específicos como el azul-blانquecino (velo azul-blanco) o el rojo (vascularización) es particularmente valiosa.

2.6.4. Diferenciación estructural (D)

Este es el criterio más complejo y específico de la dermatoscopia, referido a la identificación y evaluación de estructuras dermatoscópicas específicas asociadas con la arquitectura histológica subyacente. Incluye patrones como redes pigmentadas (retículo), glóbulos (círculos), estrías (líneas radiales o pseudópodos), áreas homogéneas (sin estructura) y estructuras de regresión como velo azul-blanco y cicatrices blancas. Su cuantificación automática pertenece al dominio del análisis de textura y reconocimiento de patrones. Técnicas como filtros de Gabor, matrices de co-ocurrencia de nivel de gris (GLCM), o descriptores LBP (Local Binary Patterns) han sido utilizadas tradicionalmente para capturar la regularidad, granularidad y direccionalidad de la textura (Argenziano y cols., 2003). Los enfoques más modernos emplean redes neuronales convolucionales entrenadas para clasificar parches de imagen en las diferentes categorías de estructuras, o modelos de segmentación semántica para delimitar regiones que contienen un patrón específico. La

integración de la información estructural (tipo, distribución, cantidad) en un score “D” automatizado es un desafío activo de investigación, pero representa la frontera para lograr sistemas de diagnóstico asistida por computadora con una precisión que rivalice con la de los expertos.

2.7. Conjunto de datos ISIC (International Skin Imaging Collaboration)

El proyecto ISIC se ha consolidado como una de las iniciativas de referencia a nivel mundial para la creación de recursos abiertos en el diagnóstico de cáncer de piel mediante imagen. Su objetivo es facilitar la colaboración internacional y el desarrollo de algoritmos estandarizados.

La edición del desafío ISIC 2018, que sirve como base para este trabajo, constituye un hito significativo por su escala y completitud (Codella y cols., 2018). Este conjunto de datos contiene un total de 2,694 imágenes dermatoscópicas, divididas en 2,594 para entrenamiento, 100 para validación y 1,000 para prueba. Cada imagen cuenta con una máscara de segmentación (ground truth) anotada manualmente por expertos, lo que lo hace invaluable para la investigación en segmentación.

Las imágenes presentan resoluciones variables, con un tamaño promedio de aproximadamente $2,166 \times 3,188$ píxeles, capturando un nivel de detalle suficiente para el análisis de estructuras finas. Una característica crucial es la diversidad diagnóstica incluida: el conjunto abarca melanomas malignos, nevus melanocíticos benignos y queratosis seborreicas, representando así un espectro clínico relevante. Además, el proyecto ISIC proporciona metadatos clínicos (como la edad y el sexo del paciente) y dermatoscópicos (tipo de dermatoscopia) para un subconjunto de las imágenes, aunque estos no son utilizados universalmente en las tareas de segmentación básica.

La existencia de este repositorio ha permitido la comparación directa de numerosos algoritmos en condiciones controladas a través de competiciones anuales, estableciendo una línea base de rendimiento para la comunidad científica.

2.8. Limitaciones actuales y brechas de investigación

A pesar del progreso significativo, el campo de la segmentación médica presenta varias limitaciones:

1. **Falta de estandarización:** Ausencia de protocolos estandarizados para preprocesamiento, aumento de datos y evaluación dificulta la comparación directa entre métodos (Marchetti y cols., 2020).
2. **Sesgos en conjuntos de datos:** La mayoría de datasets disponibles presentan desbalance en términos de tipos de lesiones, fototipos de piel y representación demográfica (Adamson y Smith, 2020).
3. **Evaluación clínica limitada:** Pocos estudios evalúan el impacto real de los sistemas de segmentación en procesos diagnósticos clínicos o en la mejora de resultados en pacientes (Navarrete-Dechent y cols., 2021).
4. **Interpretabilidad:** Las redes neuronales profundas funcionan como cajas negras, limitando la confianza clínica y la identificación de modos de fallo (Reis, Turk, Khoshelham, y Kaya, 2021).
5. **Integración en flujos de trabajo:** Escasa investigación sobre cómo integrar estos sistemas en entornos clínicos reales considerando aspectos de usabilidad, interoperabilidad y flujos de trabajo existentes (Young, Xiong, Pfau, Keiser, y Wei, 2020).

Este trabajo busca contribuir a cerrar algunas de estas brechas mediante una evaluación comparativa rigurosa de múltiples arquitecturas y el desarrollo de una herramienta integrada que facilite la transición desde la investigación hacia aplicaciones clínicas prácticas.

3. Metodología

3.1. Introducción

Este capítulo describe la metodología empleada en el desarrollo del sistema de segmentación de lesiones cutáneas y cálculo de métricas ABCD. La metodología se estructura en cinco componentes principales: conjunto de datos y preprocesamiento, arquitecturas de segmentación implementadas, configuración experimental y técnicas de entrenamiento, métricas de evaluación y desarrollo de la aplicación web. Se ha seguido un enfoque sistemático y reproducible, documentando todos los pasos del pipeline experimental para garantizar la validez científica de los resultados.

3.2. Análisis exploratorio del conjunto datos (EDA)

El International Skin Imaging Collaboration (ISIC) 2018 es un conjunto de datos público ampliamente utilizado en investigación dermatológica computacional (Codella y cols., 2018). La edición utilizada en este trabajo presenta las siguientes características:

Tabla 3.1: Distribución del conjunto de datos ISIC 2018

Conjunto	Imágenes	Máscaras	Resolución media (alto $\times$ ancho)
Entrenamiento	2,594	2,594	2,166 $\times$ 3,188 píxeles
Validación	100	100	1,775 $\times$ 2,448 píxeles
Prueba	1,000	1,000	1,850 $\times$ 2,529 píxeles

Las imágenes, capturadas mediante dermatoscopios de diversos fabricantes y modelos, se proporcionan en formato JPG con compresión variable, mientras que las máscaras de segmentación son archivos PNG binarios (0 para fondo, 255 para lesión), anotadas manualmente por expertos siguiendo un protocolo estandarizado. La correspondencia unívoca de nomenclatura entre imagen y máscara es:

- ISIC_XXXXXXX.jpg
- ISIC_XXXXXXX.segmentation.png.

La utilidad práctica y el rendimiento final de los modelos entrenados con este dataset

dependen críticamente de un análisis exploratorio de datos (EDA) minucioso que identifique sesgos, variabilidades y desafíos inherentes que deben ser abordados durante el diseño del modelo y el preprocesamiento. Esta sección presenta un análisis cuantitativo y cualitativo exhaustivo del conjunto de datos empleado en este trabajo, desglosando sus características.

3.2.1. Variabilidad en dimensiones y relación de aspecto

El análisis estadístico muestra alta variabilidad en las dimensiones originales de las imágenes: las alturas oscilan entre 542 y 6,698 píxeles y los anchos entre 718 y 9,895 píxeles. Esta variabilidad extrema refleja diferencias reales en los protocolos de adquisición clínica, la distancia del dermatoscopio a la piel y el área corporal examinada. Más importante aún que las dimensiones absolutas es la relación de aspecto, que también varía significativamente.

Un redimensionamiento ingenuo a una resolución fija, lo cual es una necesidad práctica para el entrenamiento de redes neuronales convolucionales, sin preservar la relación de aspecto puede introducir distorsiones geométricas no naturales que afectan a la morfología de la lesión, un criterio diagnóstico clave (*e.g.*, en la evaluación del “Borde” en la regla ABCD). Por lo tanto, debe utilizarse una estrategia de preprocesamiento cuidadosa de redimensionamiento manteniendo la relación de aspecto seguido de un relleno (*padding*) homogéneo, para minimizar la distorsión y preservar la información morfológica.

3.2.2. Heterogeneidad en las distribuciones de intensidad de píxeles

El análisis de los histogramas de intensidad de los canales RGB a nivel de conjunto revela diferencias estadísticamente significativas entre los conjuntos de entrenamiento, validación y prueba. Como se ilustra en la Figura 3.1, el conjunto de entrenamiento presenta una intensidad media de píxel notablemente más alta (155.26 en una escala de 0-255) en comparación con los conjuntos de validación (148.36) y prueba (148.10). Esta discrepancia no es aleatoria; sugiere diferencias sistemáticas en las condiciones de adquisición, como la intensidad de la fuente de luz, la calibración del color del dispositivo, o incluso el tono de piel promedio de la población muestreada en cada subconjunto.

Para un modelo de aprendizaje profundo, esta discrepancia representa un cambio de dominio (*domain shift*) entre el entrenamiento y la evaluación, lo que puede degradar severamente el rendimiento. Esta observación justifica la implementación obligatoria de técnicas de normalización robustas, preferiblemente la normalización por instancia (*Instance Normalization*) o por grupo (*Group Normalization*) durante el entrenamiento, que son menos sensibles a las diferencias estadísticas globales entre lotes que la normalización por lotes tradicional.

3.2.3. Análisis de la cobertura y morfología de las lesiones

La proporción del área de la imagen ocupada por la lesión, o cobertura, es una métrica crucial que impacta directamente en el desbalance de clases a nivel de píxel. El análisis calcula la cobertura media como el porcentaje de píxeles etiquetados como lesión respecto al total de píxeles de la imagen. Los resultados muestran una variabilidad moderada pero no despreciable: 21.40 % en entrenamiento, 26.85 % en validación y 27.99 % en prueba.

Esta tendencia ascendente sugiere que las lesiones en los conjuntos de evaluación son, en promedio, ligeramente más grandes en relación con el marco de la imagen. Además, un análisis más profundo de las máscaras (detallado en la subsección 4.1.2) revela una complejidad morfológica variable, con diferencias significativas en la densidad de bordes y la compacidad entre los conjuntos. Esta heterogeneidad subraya la necesidad crítica de emplear técnicas de aumento de datos (*data augmentation*) avanzadas y específicas del dominio.

Las transformaciones geométricas (como desplazamientos, rotaciones y zoom) deben ser lo suficientemente agresivas para simular la amplia gama de tamaños, formas y ubicaciones de las lesiones encontradas en la práctica clínica, mejorando así la capacidad de generalización del modelo. La combinación de estos hallazgos del EDA proporciona una base empírica sólida para justificar cada una de las decisiones de preprocesamiento y aumento de datos implementadas en la metodología de este trabajo.

3.2.4. Calidad de máscaras

El EDA de las máscaras ground truth del conjunto de datos indica una variabilidad significativa entre los conjuntos de entrenamiento, validación y prueba, lo que sugiere que




Figura 3.1: Distribución de características en los conjuntos de entrenamiento, validación y prueba

la partición no fue estratificada según estas propiedades morfológicas, añadiendo un nivel adicional de dificultad a la generalización del modelo.

La densidad de bordes, definida como la proporción de píxeles de borde respecto al área total de la máscara y calculada mediante detección de contornos, es un indicador de la complejidad del perímetro. Los valores observados (0.3671 en train, 0.4649 en val, 0.5058 en test) muestran una tendencia ascendente, indicando que las lesiones en los conjuntos de validación y de prueba tienden a presentar contornos más irregulares que aquellas en el conjunto de entrenamiento.

La compacidad (definida como P^2/A , donde P es el perímetro y A el área) es otra medida de forma que penaliza la irregularidad. Un círculo perfecto tiene la compacidad mínima (aproximadamente $4\pi \approx 12,57$) y valores más altos indican formas más complejas y alargadas. Los valores medios muestran una notable diferencia: 4.42 (train), 2.21 (val), 3.71 (test). El valor excepcionalmente bajo en validación sugiere que las lesiones en este conjunto son, en promedio, notablemente más compactas y posiblemente de forma más regular que en los otros conjuntos.

Finalmente, el área media de la lesión (en píxeles) también presenta variaciones entre los distintos splits del conjunto de datos: 9,761 (train), 6,217 (val), 7,724 (test). Esta

diferencia en la escala de los objetos de interés tiene implicaciones prácticas para el diseño de la arquitectura y el preprocesamiento. Por ejemplo, lesiones más pequeñas pueden ser más susceptibles a ser “perdidas” o segmentadas de manera incompleta por modelos cuyo campo receptivo no esté bien calibrado para capturar contexto suficiente alrededor de objetos pequeños.

3.3. Preprocesamiento y aumento de datos

La calidad y robustez de un modelo de aprendizaje profundo dependen críticamente no solo de su arquitectura, sino también de cómo se preparan y enriquecen los datos de entrada. En el dominio de la segmentación médica, un pipeline de preprocesamiento y aumento de datos bien diseñado es esencial para abordar desafíos específicos como la alta variabilidad en la adquisición de imágenes, el desbalance extremo de clases a nivel de píxel y el riesgo de sobreajuste debido al tamaño limitado de los conjuntos de datos. Esta sección detalla la metodología sistemática implementada para transformar las imágenes crudas del conjunto ISIC 2018 en un formato óptimo para el entrenamiento, incorporando transformaciones que simulan la variabilidad del mundo real y mejoran la capacidad de generalización de los modelos.

3.3.1. Pipeline de preprocesamiento

Se implementó un pipeline de preprocesamiento modular, reproducible y basado en estándares, diseñado para ser aplicado de manera consistente a todos los conjuntos de datos (entrenamiento, validación y prueba). Este pipeline transforma cada par imagen-máscara en un tensor normalizado listo para la red neuronal.

Redimensionamiento uniforme con preservación de relación de aspecto

El primer paso consiste en estandarizar las dimensiones de entrada. Como reveló el análisis exploratorio, las imágenes originales presentan una variabilidad extrema en tamaño y relación de aspecto (alturas entre 542 y 6,698 píxeles; anchos entre 718 y 9,895 píxeles). Se optó por un redimensionamiento a 256×256 píxeles. Esta resolución fue seleccionada tras un análisis de compromiso (*trade-off*): dimensiones mayores (*e.g.*, 512×512) retienen más detalles espaciales finos, cruciales para bordes precisos, pero incrementan cuadráticamente la demanda de memoria y el tiempo de cómputo; dimensiones menores

(*e.g.*, 128×128) son más eficientes pero pueden perder información crítica para lesiones pequeñas o estructuras complejas. Siguiendo recomendaciones de trabajos comparativos en segmentación dermatológica (Yuan, Chao, y Lo, 2020), 256×256 representa un punto óptimo.

Crucialmente, se implementó una estrategia de **redimensionamiento preservando la relación de aspecto** seguida de *padding* centrado. Un redimensionamiento ingenuo a una resolución cuadrada fija puede introducir distorsiones geométricas no naturales que afectan a la morfología de la lesión, un criterio diagnóstico clave en la evaluación del criterio “Borde” de la regla ABCD. El algoritmo implementado funciona de la siguiente manera:

1. Se calcula el factor de escala que permite que el lado más largo de la imagen quepa en la dimensión objetivo, manteniendo la proporción.
2. Se redimensiona la imagen usando este factor único, resultando en una imagen donde al menos una dimensión coincide con el objetivo.
3. Se añade *padding* negro (valor 0) centrado para completar las dimensiones hasta alcanzar 256×256 .

Para las imágenes, se utilizó interpolación bilineal (`cv2.INTER_LINEAR`), que proporciona un buen balance entre calidad y eficiencia. Para las máscaras de segmentación, esencialmente imágenes binarias, se aplicó interpolación por vecino más cercano (`cv2.INTER_NEAREST`) para evitar la creación de valores intermedios (*e.g.*, 0.5) que destruirían la naturaleza binaria del ground truth. El valor de *padding* para las máscaras es también 0, correspondiente a la clase “fondo”.

Normalización de intensidades

Las intensidades de píxeles se normalizaron utilizando estadísticas calculadas específicamente sobre el conjunto de datos ISIC 2018:

$$I_{\text{norm}} = \frac{I_{\text{original}} - \mu}{\sigma}$$

donde $\mu = [0,4963, 0,4088, 0,3765]$ y $\sigma = [0,3505, 0,3015, 0,2895]$ para los canales RGB respectivamente. A diferencia del enfoque común de utilizar estadísticas de ImageNet, se

optó por calcular estadísticas específicas del dominio dermatoscópico. Las imágenes dermatoscópicas presentan características cromáticas muy distintas a las imágenes naturales: tonos predominantes de piel, presencia de vello y características específicas de las lesiones. La normalización con estadísticas propias del dominio mejora la estabilidad numérica durante el entrenamiento y asegura que los valores de entrada estén centrados y escalados de manera óptima para el problema específico de segmentación de lesiones cutáneas.

Estandarización de máscaras y preparación de tensores

Las máscaras PNG, originalmente con valores 0 (fondo) y 255 (lesión), se convirtieron primero a un formato binario estricto con valores 0 y 1. Luego, estas matrices se almacenaron como tensores de tipo `float32`, que es el tipo de dato esperado por la mayoría de frameworks de deep learning para calcular funciones de pérdida y gradientes de manera eficiente. Este paso asegura la compatibilidad total con las operaciones posteriores del pipeline de entrenamiento.

3.3.2. Estrategias de aumento de datos

Dado el tamaño limitado del conjunto de entrenamiento (2,594 imágenes) y la necesidad de que los modelos generalicen a variaciones no vistas, se implementó un esquema agresivo y específico del dominio de aumento de datos (*data augmentation*). Estas transformaciones se aplican on-the-fly durante el entrenamiento, generando efectivamente un conjunto de datos infinito y variado. Todas las transformaciones se aplican de manera consistente tanto a la imagen como a su máscara correspondiente, preservando la alineación espacial. Se utilizó la biblioteca Albumentations (Buslaev y cols., 2020) por su eficiencia y soporte robusto para transformaciones espaciales aplicadas a imágenes y máscaras simultáneamente.

La elección de transformaciones se basa en dos principios: 1) Simular variabilidad realista en las condiciones de adquisición (cambios en iluminación, color, ángulo de la cámara) y 2) Aumentar la invarianza del modelo a transformaciones geométricas que no alteran la naturaleza de la lesión. Por ejemplo, las rotaciones y volteos son invarianzas naturales en imágenes de piel ya que la orientación de la cámara durante la adquisición es arbitraria. Las transformaciones de color (brillo, contraste, saturación) simulan diferencias en la iluminación del dermatoscopio y el tipo de piel del paciente. CLAHE (*Contrast Limited*

Tabla 3.2: Transformaciones de aumento de datos aplicadas

Transformación	Probabilidad	Parámetros/Rango
Volteo horizontal	0.5	-
Volteo vertical	0.5	-
Rotación aleatoria	0.5	± 30 grados
Transformación afín	0.5	Traslación: $\pm 10\%$, Escala: $\pm 20\%$
Cambio de brillo/contraste	0.5	Brillo: ± 0.2 , Contraste: ± 0.2
Hue/Saturación/Value	0.5	Hue: ± 20 , Sat: ± 30 , Val: ± 20
CLAHE	0.3	clip_limit=4.0, tile_grid_size=(8,8)
Desenfoque Gaussiano	0.3	blur_limit=3

Adaptive Histogram Equalization) mejora el contraste local, ayudando al modelo a ser más robusto ante variaciones en la calidad de imagen.

Todas las transformaciones espaciales se aplicaron de manera consistente tanto a las imágenes como a las máscaras correspondientes, preservando la correspondencia espacial. Se utilizó la biblioteca Albumentations (Buslaev y cols., 2020) para implementar estas transformaciones de manera eficiente, aprovechando su soporte nativo para transformaciones duales (imagen + máscara).

3.3.3. Manejo del desbalance de clases

El desbalance de clases a nivel de píxel es, quizás, el desafío más crítico en segmentación dermatológica. En una imagen típica, el fondo (clase mayoritaria) puede superar en un orden de magnitud (de 4:1 a más de 20:1) al área de la lesión (clase minoritaria). Si no se maneja, los modelos aprenden rápidamente a predecir “fondo” para todos los píxeles, minimizando la pérdida global pero fallando completamente en la tarea. Para contrarrestar esto, se implementaron dos estrategias complementarias a nivel de muestreo y de función de optimización.

Muestreo aleatorio ponderado (*Weighted Random Sampler*)

En lugar de muestrear imágenes del conjunto de entrenamiento de manera uniforme, se implementó un Weighted Random Sampler que asigna una probabilidad de muestreo

a cada imagen inversamente proporcional a la frecuencia de su clase minoritaria (lesión). En la práctica, esto significa que las imágenes con una cobertura de lesión muy baja (*e.g.*, $<5\%$ del área) reciben un peso mayor. Esto asegura que en cada época de entrenamiento, el modelo vea una representación adecuada de casos “difíciles” con lesiones pequeñas, evitando que se sesgue hacia imágenes donde la lesión es grande y fácil de segmentar.

Funciones de pérdida robustas al desbalance

En el nivel de la función de optimización, se seleccionaron funciones de pérdida que son intrínsecamente robustas al desbalance de clases. La Dice Loss, derivada del coeficiente de Sorensen-Dice, optimiza directamente para la superposición entre regiones, siendo insensible al tamaño absoluto de las clases (Milletari y cols., 2016). Como se discutió en la Sección 2.3, la combinación estándar en el campo es la pérdida combinada BCE + Dice:

$$\mathcal{L}_{\text{total}} = \lambda \cdot \mathcal{L}_{\text{BCE}} + (1 - \lambda) \cdot \mathcal{L}_{\text{Dice}}, \quad \text{con } \lambda = 0,5.$$

Esta combinación aprovecha los gradientes suaves de la entropía cruzada binaria (BCE) para un aprendizaje estable y la propiedad de invarianza a escala de la pérdida Dice para enfocarse en la superposición de la región de interés. La sinergia de estas dos estrategias—muestreo ponderado y funciones de pérdida especializadas—proporciona un marco sólido para entrenar modelos que no ignoran la clase minoritaria crítica.

3.4. Arquitecturas de segmentación implementadas

Se implementaron y compararon las seis arquitecturas representativas del estado del arte en segmentación semántica presentadas en el Capítulo 2, haciendo uso para ello de la librería en PyTorch 1.12.1.

3.4.1. U-Net Básica

Implementación de la arquitectura original propuesta por Ronneberger et al. (Ronneberger y cols., 2015), con normalización por lotes añadida para mejorar la estabilidad del entrenamiento:

- **Encoder:** 4 bloques de downsampling con características [64, 128, 256, 512], cada uno con dos convoluciones 3×3 seguidas de BatchNorm, ReLU y max pooling 2×2

- **Bottleneck:** Bloque convolucional con 1024 características
- **Decoder:** 4 bloques de upsampling mediante convoluciones transpuestas 2×2
- **Conexiones de salto:** Concatenación de características del encoder a la entrada correspondiente del decoder
- **Capas finales:** Convolución 1×1 para generar logits (la función sigmoide se aplica en la función de pérdida)

3.4.2. Attention U-Net

Implementación basada en Oktay et al. (Oktay y cols., 2018) con mecanismos de atención en las conexiones de salto:

- **Mecanismo de atención:** Gate Attention Unit que calcula coeficientes de atención $\alpha \in [0, 1]$ para cada localización espacial
- **Función de atención:** $\alpha = \sigma(\mathbf{W}_x^T \mathbf{x} + \mathbf{W}_g^T \mathbf{g} + b)$
- **Características atentas:** $\mathbf{x}_{\text{att}} = \alpha \cdot \mathbf{x}$
- **Ventajas:** Enfoque selectivo en regiones relevantes, supresión de características de fondo irrelevantes

3.4.3. Residual U-Net

Arquitectura que incorpora bloques residuales inspirada en ResNet de He et al. (He y cols., 2016):

- **Bloques residuales:** $\mathbf{y} = \mathcal{F}(\mathbf{x}, \{\mathbf{W}_i\}) + \mathbf{x}$
- **Bloque básico:** Dos convoluciones 3×3 con normalización por lotes y ReLU
- **Conectividad:** Conexiones residuales tanto en encoder como decoder
- **Ventajas:** Mejor flujo de gradientes, entrenamiento más estable, capacidad para redes más profundas

3.4.4. U-Net++

Implementación de la arquitectura anidada propuesta por Zhou et al. (Zhou y cols., 2018):

- **Estructura anidada:** Múltiples niveles de U-Nets interconectados
- **Conexiones densas:** Cada nodo recibe entrada de todos los nodos anteriores en el mismo nivel
- **Supervisión profunda:** Salidas intermedias en diferentes niveles para supervisión auxiliar
- **Configuración utilizada:** features = [32, 64, 128, 256], deep_supervision = False (por limitaciones de memoria)

3.4.5. DeepLabV3+

Implementación de la arquitectura propuesta por Chen et al. (L.-C. Chen y cols., 2018) con ASPP:

- **Backbone:** Encoder convolucional con 4 niveles de características [64, 128, 256, 512]
- **ASPP (Atrous Spatial Pyramid Pooling):** Tres tasas de dilatación [6, 12, 18], una convolución 1×1 y average pooling global. Cada rama produce 256 canales.
- **Fusión multiescala:** $\mathbf{F} = \text{Concat}[\text{Conv}_{1 \times 1}(\mathbf{x}), \text{Conv}_{r=6}(\mathbf{x}), \text{Conv}_{r=12}(\mathbf{x}), \text{Conv}_{r=18}(\mathbf{x}), \text{GAP}(\mathbf{x})]$
- **Decoder:** Combinación de características de bajo nivel del encoder con características semánticas del ASPP mediante upsampling bilineal y skip connections

3.4.6. TransUNet

Implementación de la arquitectura híbrida CNN-Transformer propuesta por Chen et al. (J. Chen y cols., 2021):

- **Encoder híbrido:**
 1. Extracción de características multi-escala mediante CNN simplificada (similar a ResNet pero más ligera)
 2. Proyección a secuencias de patches mediante convolución 1×1

3. Procesamiento mediante capas Transformer con Pre-Norm

- **Transformer:** 8 capas, 8 cabezas de atención, dimensión embebida 512
- **Mecanismo de atención:** $\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) V$
- **Decoder CNN:** Bloques de upsampling con convoluciones transpuestas 2×2 y skip connections desde el encoder CNN
- **Regularización:** Gradient clipping ($\text{max_norm}=1.0$) durante el entrenamiento para estabilidad

3.5. Configuración experimental

La validez y reproducibilidad de los resultados en aprendizaje profundo dependen críticamente de una configuración experimental rigurosa y bien documentada. En este trabajo, se implementaron meticulosamente protocolos para garantizar que todas las ejecuciones fueran deterministas y que las comparaciones entre arquitecturas fueran justas, minimizando la influencia de la aleatoriedad en la inicialización, el muestreo de datos y las operaciones de la GPU. Toda la experimentación se realizó bajo condiciones controladas, con semillas fijas y configuraciones de hardware y software consistentes.

3.5.1. Entorno computacional

Todos los experimentos de entrenamiento y evaluación se ejecutaron en una estación de trabajo de alto rendimiento con una configuración homogénea para garantizar la consistencia en los tiempos de cómputo y el uso de memoria. La Tabla 3.3 detalla la especificación técnica completa.

Para asegurar la reproducibilidad exacta, se configuró PyTorch en modo determinista: `torch.backends.cudnn.deterministic = True` y `torch.backends.cudnn.benchmark = False`. Esto fuerza a que las operaciones de convolución de cuDNN usen algoritmos deterministas, a costa de un ligero sacrificio en el rendimiento. Además, se fijaron todas las semillas aleatorias relevantes a 42: `random.seed(42)`, `np.random.seed(42)` y `torch.manual_seed(42)`.

Tabla 3.3: Configuración del entorno computacional

Componente	Especificación
Procesador	AMD Ryzen 7 7800X3D (8 núcleos)
GPU	NVIDIA GeForce RTX 4080 (16 GB)
RAM	64 GB DDR5 6000 MHz
Sistema operativo	Ubuntu 22.04 LTS
Framework	PyTorch 1.12.1, CUDA 11.7
Bibliotecas auxiliares	Torchvision 0.13.1, Albumentations 1.3.0, OpenCV 4.7.0

3.5.2. Hiperparámetros y configuración de entrenamiento

Se diseñó una configuración de hiperparámetros específica para cada familia de arquitecturas, basándose en la literatura especializada y en experimentos piloto. El objetivo fue optimizar el rendimiento de cada modelo dentro de un marco de comparación justo, donde todos tuvieran la oportunidad de converger adecuadamente. La Tabla 3.4 resume la configuración clave.

Tabla 3.4: Configuración de hiperparámetros por arquitectura

Arquitectura	Learning Rate	Weight Decay	Scheduler
U-Net	1e-4	1e-5	Plateau
Att. U-Net	1e-4	1e-5	Plateau
Res. U-Net	1e-4	1e-5	Plateau
U-Net++	1e-4	1e-4	Plateau
DeepLabV3+	1e-4	1e-4	Polynomial
TransUNet	1e-4	1e-2	Cosine

El batch size se fijó en 16 para todos los modelos, como un compromiso entre la estabilidad de la estimación del gradiente y las limitaciones de memoria de la GPU. El número máximo de épocas fue 100, aunque en la práctica el mecanismo de *early stopping* detenía el entrenamiento antes.

3.5.3. Funciones de pérdida

Para todas las arquitecturas se utilizó la misma función de pérdida combinada, que ha demostrado ser un estándar de facto en segmentación médica por su robustez al desbalance de clases (Isensee y cols., 2021). Esta función combina la Entropía Cruzada Binaria (BCE) y la Pérdida Dice:

$$\mathcal{L}_{\text{total}} = \lambda_{\text{BCE}} \cdot \mathcal{L}_{\text{BCE}} + \lambda_{\text{Dice}} \cdot \mathcal{L}_{\text{Dice}}$$

con pesos equilibrados: $\lambda_{\text{BCE}} = 0,5$ y $\lambda_{\text{Dice}} = 0,5$.

La pérdida BCE proporciona gradientes suaves en todo el espacio de probabilidad, favoreciendo un aprendizaje estable desde el inicio:

$$\mathcal{L}_{\text{BCE}} = -\frac{1}{N} \sum_{i=1}^N [y_i \log(p_i) + (1 - y_i) \log(1 - p_i)]$$

donde $y_i \in 0, 1$ es la etiqueta verdadera, $p_i \in [0, 1]$ es la probabilidad predicha y N es el número total de píxeles.

La pérdida Dice optimiza directamente para la superposición entre regiones, siendo robusta al desbalance:

$$\mathcal{L}_{\text{Dice}} = 1 - \frac{2 \sum_{i=1}^N p_i y_i + \epsilon}{\sum_{i=1}^N p_i + \sum_{i=1}^N y_i + \epsilon}$$

Se añade un término de suavizado $\epsilon = 1 \times 10^{-6}$ para garantizar estabilidad numérica y evitar divisiones por cero cuando la predicción y la verdad fundamental sean ambas cero.

3.5.4. Técnicas de entrenamiento

Learning Rate Warmup

Para mitigar la inestabilidad en las primeras iteraciones, especialmente crítica en modelos grandes o con inicializaciones preentrenadas, se implementó un calentamiento lineal (*linear warmup*) de la tasa de aprendizaje durante las primeras 5 épocas:

$$\text{lr}_{\text{epoch}} = \text{lr}_{\text{base}} \times \min \left(1, \frac{\text{epoch}}{\text{warmup_epochs}} \right)$$

Esta estrategia permite que los estadísticos de las capas de normalización se estabilicen y que los gradientes comiencen a fluir de manera controlada antes de alcanzar la tasa de aprendizaje objetivo.

Planificadores de tasa de aprendizaje (Schedulers)

Se emplearon diferentes estrategias de ajuste de la tasa de aprendizaje adaptadas a cada arquitectura:

- **ReduceLROnPlateau:** Utilizado para la familia U-Net. Reduce la LR por un factor de 0.5 cuando el Dice Score en validación deja de mejorar durante 5 épocas consecutivas. Es una estrategia conservadora y efectiva para modelos que convergen de manera estable.
- **Decaimiento polinómico:** Aplicado a DeepLabV3+. La LR decae siguiendo una curva polinómica de potencia 0.9 a lo largo de las épocas, lo que proporciona un descenso suave y predecible.
- **Annealing de coseno:** Utilizado para TransUNet. La LR sigue una función coseno que decae desde el valor inicial hasta un mínimo ($\text{eta_min}=1\text{e-}6$) en ciclos de 30 épocas. Esta estrategia, popularizada en el entrenamiento de Transformers, permite reinicios periódicos que pueden ayudar a escapar de mínimos locales.

Early Stopping

Se implementó un mecanismo de parada temprana (*early stopping*) con los siguientes parámetros: se monitorizó el Dice Score en el conjunto de validación; si este no mejoraba en al menos 0.001 (**min_delta**) durante 10 épocas consecutivas (**patience**), el entrenamiento se detenía. El modelo guardado correspondía a la época con el mejor valor de Dice en validación. Esto previene el sobreajuste y ahorra significativos recursos computacionales.

3.5.5. Optimizador

Para optimizar los pesos de todas las arquitecturas se seleccionó AdamW (Loshchilov y Hutter, 2017), una variante del optimizador Adam que realiza un decaimiento de pesos desacoplado (*decoupled weight decay*). A diferencia de la regularización L2 tradicional, que

modifica la función de pérdida, AdamW aplica el decaimiento de pesos directamente a los parámetros durante la actualización, lo que conduce a una generalización mejorada y es la configuración estándar para modelos modernos. La regla de actualización para un parámetro θ en el paso t es:

$$\theta_t = \theta_{t-1} - \eta \left(\frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon} + \lambda \theta_{t-1} \right)$$

donde η es la tasa de aprendizaje, $\hat{m}_t$ y $\hat{v}_t$ son las estimaciones de primer y segundo momento corregidas por sesgo, $\epsilon = 1 \times 10^{-8}$ es un término de estabilidad y λ es el coeficiente de decaimiento de pesos (véase la Tabla 3.4). Se utilizaron los valores por defecto para los momentos: $\beta_1 = 0,9$ y $\beta_2 = 0,999$.

3.6. Métricas de evaluación

La evaluación cuantitativa del rendimiento de los modelos de segmentación requiere un conjunto comprensivo y bien definido de métricas que capturen diferentes aspectos de la calidad de la segmentación. En el contexto médico, no basta con una única medida de exactitud; es necesario evaluar tanto la superposición espacial global como la fiabilidad de las detecciones positivas, la exhaustividad y la consistencia a través de diferentes casos clínicos. Esta sección detalla las métricas estándar implementadas en este trabajo, su definición matemática y su interpretación clínica y computacional relevante para la tarea de segmentación de lesiones cutáneas.

3.6.1. Métricas por píxel

Las métricas por píxel evalúan la correspondencia entre la máscara binaria predicha por el modelo (Y) y la máscara de referencia o *ground truth* (X), considerando los cuatro posibles resultados en cada píxel: Verdaderos Positivos (TP), Verdaderos Negativos (TN), Falsos Positivos (FP) y Falsos Negativos (FN). La Tabla 3.5 resume las métricas clave utilizadas.

La selección del Dice Score como métrica principal para la selección de modelos y comparación está alineada con la práctica estándar en la comunidad de segmentación médica (Milletari y cols., 2016; Isensee y cols., 2021). Su robustez al desbalance y su interpretación directa como medida de superposición la hacen ideal para esta tarea. Sin embargo, el

Tabla 3.5: Métricas de evaluación implementadas

Métrica	Rango	Definición/Interpretación
Dice Score (F1)	$[0, 1]$	$\frac{2 X \cap Y }{ X + Y }$, mide superposición
IoU (Jaccard)	$[0, 1]$	$\frac{ X \cap Y }{ X \cup Y }$, más estricto que Dice
Precisión	$[0, 1]$	$\frac{TP}{TP + FP}$, proporción de positivos correctos
Recall (Sensibilidad)	$[0, 1]$	$\frac{TP}{TP + FN}$, capacidad de detectar positivos
Exactitud	$[0, 1]$	$\frac{TP + TN}{TP + TN + FP + FN}$, precisión global
Pérdida BCE	$[0, \infty)$	Cross-entropy entre predicción y ground truth

análisis conjunto de Precisión y Recall es indispensable para un diagnóstico completo del comportamiento del modelo: un alto Dice Score puede resultar de diferentes combinaciones de estos dos factores y el compromiso (*trade-off*) entre ellos tiene implicaciones clínicas distintas (e.g., un modelo con alta precisión pero bajo recall podría ser útil como segunda opinión conservadora, mientras que uno con alto recall pero menor precisión podría ser mejor para cribado).

3.6.2. Métricas por imagen y análisis de variabilidad

Más allá de los promedios globales sobre todo el conjunto de prueba, es fundamental analizar la variabilidad en el rendimiento a nivel de imagen individual. Esto permite identificar subgrupos de casos donde los modelos fallan consistentemente y relacionar el rendimiento con características de la lesión. Para ello, se calcularon las siguientes estadísticas y análisis:

- **Estadísticas por imagen:** Para cada imagen en el conjunto de prueba, se calculó el Dice Score individual. Luego, se analizó la distribución de estos scores a través de su media, mediana, desviación estándar y rango intercuartílico (IQR). Una desviación estándar alta indica un rendimiento inconsistente, mientras que una mediana muy por debajo de la media sugiere la presencia de valores atípicos (imágenes con segmentación muy pobre).
- **Análisis por tamaño de lesión:** Las imágenes se agruparon en cuartiles según el área de la lesión en el *ground truth*. Para cada grupo (lesiones muy pequeñas, pequeñas, medianas, grandes), se calculó el Dice Score promedio de cada modelo.

Este análisis revela si un modelo es particularmente débil o fuerte para segmentar lesiones de un tamaño específico, una información valiosa para su aplicación práctica.

- **Análisis de casos extremos:** Se identificaron de manera sistemática las imágenes con el mejor y peor Dice Score para cada arquitectura. El examen cualitativo de estos casos límite (junto con sus métricas de Precisión y Recall asociadas) proporciona información invaluable sobre los patrones de error característicos de cada modelo. Por ejemplo, si los peores casos de un modelo suelen ser lesiones con bordes muy difusos, esto señala una debilidad específica de su diseño.

3.7. Desarrollo de la aplicación web

El objetivo último de esta investigación no se limita a la comparación teórica de arquitecturas, sino a la creación de una herramienta práctica que pueda ser utilizada por investigadores y, potencialmente, por profesionales clínicos. Para ello, se desarrolló una aplicación web que permite cargar imágenes dermatoscópicas, ejecutar inferencia con cualquiera de los seis modelos entrenados, visualizar los resultados de la segmentación y, de manera innovadora, calcular automáticamente las métricas ABCD derivadas de la máscara segmentada. Esta aplicación encapsula todo el flujo de trabajo de análisis en una interfaz accesible y de uso intuitivo.

3.7.1. Arquitectura del sistema

La aplicación se basa en una arquitectura cliente-servidor moderna y desacoplada, que separa claramente la lógica de procesamiento (backend) de la interfaz de usuario (frontend). Esta separación permite una mayor escalabilidad, mantenibilidad y permite que ambos componentes evolucionen de forma independiente.

Backend (Servidor API)

El backend actúa como el motor de procesamiento de la aplicación. Se implementó utilizando FastAPI, un framework web moderno y de alto rendimiento para Python que permite crear APIs REST de forma sencilla y con soporte nativo para operaciones asíncronas, crucial para manejar múltiples peticiones de inferencia de forma eficiente.

- **Carga y gestión de modelos:** Los seis modelos de segmentación entrenados (U-Net, Attention U-Net, Residual U-Net, U-Net++, DeepLabV3+, TransUNet) se car-

gan en la memoria de la GPU durante el inicio del servidor. Esto elimina la sobrecarga de carga/descarga por cada petición, optimizando el tiempo de inferencia.

- **Pipeline de procesamiento:** Para garantizar la consistencia con los resultados del entrenamiento, se implementa un pipeline idéntico al utilizado durante la fase experimental: redimensionamiento a 256×256 preservando la relación de aspecto mediante *padding* centrado (para evitar distorsiones geométricas en la morfología de la lesión), normalización con estadísticas calculadas del conjunto de entrenamiento ISIC 2018 ($\mu = [0,4963, 0,4088, 0,3765]$, $\sigma = [0,3505, 0,3015, 0,2895]$) y conversión a tensor.
- **Cálculo de métricas ABCD:** Junto con el módulo de segmentación, el backend incluye una implementación completa de los algoritmos para calcular las cuatro métricas del sistema ABCD (detalladas en la siguiente subsección), tomando como entrada la imagen original y la máscara segmentada.
- **Reconstrucción de máscara:** Tras la inferencia, la máscara predicha se reconstruye a las dimensiones originales de la imagen eliminando el *padding* añadido, garantizando que el análisis ABCD se realice sobre la geometría real de la lesión.

Frontend (Interfaz de usuario)

La interfaz de usuario se desarrolló como una aplicación de una sola página (*Single Page Application* - SPA) utilizando HTML5, CSS3 y JavaScript, con el objeto de garantizar una experiencia de usuario fluida sin dependencias de frameworks externos, contando con un diseño responsivo que se adapta a diferentes tamaños de pantalla. Utiliza la API Fetch nativa de JavaScript para realizar peticiones asíncronas al servidor, con manejo de estados de carga y errores.

3.7.2. Implementación del cálculo de métricas ABCD

Uno de los aportes centrales de la aplicación es la automatización del cálculo del sistema ABCD a partir de la máscara segmentada. Se implementaron algoritmos específicos para cada componente, combinando procesamiento de imágenes clásico con técnicas de visión por computadora.

Asimetría (A)

El cálculo de la asimetría se basa en un análisis geométrico objetivo de la máscara binaria mediante comparación de mitades reflejadas.

1. Se detecta el contorno principal de la lesión y se calculan sus momentos geométricos para determinar el centroide.
2. La máscara se divide en dos mitades (izquierda/derecha para el eje vertical, superior/inferior para el eje horizontal) utilizando el centroide como punto de división.
3. Para cada eje, una de las mitades se refleja horizontalmente (eje X) o verticalmente (eje Y) para superponerla con la otra mitad.
4. Se aplica una operación XOR lógica entre las dos mitades, identificando los píxeles que no coinciden (áreas asimétricas).
5. La asimetría en cada eje se cuantifica como la proporción de píxeles diferentes respecto al área total de la lesión:

$$\text{Asimetría}_{\text{eje}} = \frac{\text{Píxeles}_{XOR}}{\text{Área Total}}$$

6. La puntuación de asimetría total se calcula como el promedio de ambos ejes:

$$\text{Asimetría} = \frac{\text{Asimetría}_X + \text{Asimetría}_Y}{2}$$

7. Finalmente, se asigna un nivel de riesgo: Bajo ($< 0,2$), Medio ($0,2-0,4$), Alto ($> 0,4$).

Bordes (B)

La evaluación automática de los bordes se centra en cuantificar la irregularidad del contorno mediante métricas geométricas.

1. Se extrae el contorno de la máscara segmentada utilizando el algoritmo de detección de contornos de OpenCV.
2. Se calcula el área (A) y el perímetro (P) de la máscara.
3. La compacidad (o circularidad) se calcula como $C = 4\pi A/P^2$. Un círculo perfecto tiene $C = 1$ y valores menores indican formas más irregulares y complejas.

4. Se calculan las distancias radiales desde el centroide hasta cada punto del contorno.

El coeficiente de variación (CV) de estas distancias cuantifica la irregularidad:

$$\text{Irregularidad} = \frac{\sigma_{\text{distancias}}}{\mu_{\text{distancias}}}$$

donde σ es la desviación estándar y μ es la media de las distancias radiales.

5. Se aplica una aproximación poligonal al contorno para capturar la complejidad de la forma, calculando la ratio entre el número de vértices del polígono aproximado y los puntos originales del contorno.
6. La puntuación final de bordes (B) se asigna según la irregularidad y compacidad:
riesgo Bajo (compacidad $> 0,7$, irregularidad $< 0,3$), Medio (valores intermedios), Alto (compacidad $< 0,5$ o irregularidad $> 0,5$).

Color (C)

El análisis de color busca identificar la variedad cromática y detectar colores de riesgo dermatológico dentro de la lesión.

1. Se extraen los píxeles de la imagen original que corresponden a la región segmentada de la lesión.
2. La imagen se convierte al espacio de color HSV (Tono, Saturación, Valor) para el análisis de agrupamiento.
3. Se aplica el algoritmo de *clustering* K-means con $k = 6$ clusters sobre los píxeles HSV de la lesión para identificar los colores dominantes.
4. Se cuenta el número de colores significativos (clusters que representan más del 5 % de los píxeles de la lesión).
5. Se calcula la varianza de color como indicador de heterogeneidad cromática.
6. En el espacio RGB, se detectan tres colores de riesgo clínicamente relevantes:
 - **Azul-grisáceo:** Píxeles donde el canal B (azul) es mayor que los canales R (rojo) y G (verde). Presente si más del 10 % de los píxeles cumplen esta condición.
 - **Blanco:** Píxeles donde R, G y B son todos mayores a 200. Presente si más del 10 % de los píxeles cumplen esta condición.

- **Rojo:** Píxeles donde $R > 150$ y R es mayor que G y B . Presente si más del 10 % de los píxeles cumplen esta condición.

7. La puntuación de color (C) considera tanto la diversidad cromática (número de colores significativos) como la presencia de colores de riesgo, asignando niveles de riesgo: Bajo (1-2 colores, sin colores de riesgo), Medio (3-4 colores o presencia de un color de riesgo), Alto (5+ colores o múltiples colores de riesgo).

Diámetro (D)

El criterio D evalúa las dimensiones físicas de la lesión, siendo el diámetro un indicador relevante para el diagnóstico diferencial de melanoma.

1. Se detecta el contorno principal de la máscara segmentada.
2. Si el contorno tiene suficientes puntos (≥ 5), se ajusta una elipse mediante el método de mínimos cuadrados (`cv2.fitEllipse`).
3. Del ajuste elíptico se extraen los ejes mayor y menor de la lesión en píxeles.
4. Se calcula el área de la lesión en píxeles mediante `cv2.contourArea`.
5. Utilizando un factor de conversión configurable (píxeles por milímetro), se transforman las medidas a unidades físicas:

$$\text{Diámetro}_{mm} = \frac{\text{Eje Mayor}_{px}}{\text{píxeles/mm}}$$

$$\text{Área}_{mm^2} = \frac{\text{Área}_{px}}{(\text{píxeles/mm})^2}$$

6. La puntuación de diámetro (D) se asigna según umbrales clínicos: riesgo Bajo (< 6 mm), Medio ($6 - 10$ mm), Alto (> 10 mm). El umbral de 6 mm corresponde al criterio clínico tradicional ya que lesiones mayores a este valor requieren evaluación adicional.

4. Resultados experimentales

Este capítulo presenta los resultados obtenidos en cada etapa del estudio comparativo, desde el entrenamiento de los modelos hasta su evaluación con el conjunto de prueba. Los resultados se estructuran siguiendo el flujo experimental secuencial, proporcionando una visión completa del rendimiento de cada arquitectura en la tarea de segmentación de lesiones dermatoscópicas.

4.1. Entrenamiento y convergencia de modelos

Los seis modelos fueron entrenados con la misma configuración base pero con hiperparámetros específicos para cada arquitectura, como se detalló en la Sección 3.4. Todos los entrenamientos utilizaron early stopping con una paciencia de 10 épocas, monitorizando el Dice Score en el conjunto de validación. La Tabla 4.1 resume los resultados clave del proceso de entrenamiento, incluyendo la eficiencia computacional (temporal y de memoria) y el rendimiento máximo alcanzado.

Tabla 4.1: Resumen del proceso de entrenamiento de los modelos

Modelo	Épocas	Mejor Dice	Tiempo/época (s)	Parámetros (mill.)
U-Net Básica	48	0.8797	18.7	20.3
Attention U-Net	50	0.8834	23.7	31.4
Residual U-Net	34	0.8765	21.2	31.0
U-Net++	27	0.8673	18.6	39.9
DeepLabV3+	30	0.8979	6.8	32.4
TransUNet	27	0.8855	8.0	9.0

DeepLabV3+ demostró la convergencia más rápida y eficiente, alcanzando su mejor rendimiento en validación (Dice = 0.8979) en solo 30 épocas, con un tiempo por época notablemente menor al resto (6.8 segundos). Este comportamiento puede atribuirse a su arquitectura optimizada con convoluciones dilatadas que capturan contexto multiescala de manera eficiente y al uso del scheduler polinómico específicamente calibrado para esta familia de modelos, que permite un descenso suave y constante de la tasa de aprendizaje.

TransUNet también mostró una convergencia rápida (27 épocas, 8.0 s/época) y un rendimiento en validación competitivo (0.8855). Las variantes de U-Net mostraron tiempos de entrenamiento más prolongados, especialmente Attention U-Net (23.7 s/época), lo que puede relacionarse directamente con el costo computacional adicional de calcular y aplicar los mapas de atención en cada conexión de salto. U-Net++, a pesar de su arquitectura aparentemente más compleja con conexiones densas, mostró uno de los tiempos totales de entrenamiento más bajos (8.4 minutos), terminando en sólo 27 épocas, lo que sugiere que su diseño con supervisión profunda facilita una convergencia más rápida hacia un óptimo razonable.

En términos de eficiencia paramétrica, U-Net++ destaca notablemente al lograr un rendimiento competitivo (Dice = 0.8552) con solo 9.0 millones de parámetros, menos de la mitad que los modelos de la familia U-Net clásica (~31 M) y aproximadamente una cuarta parte de TransUNet (39.9 M). DeepLabV3+, con 20.3 millones de parámetros, ofrece el mejor compromiso entre rendimiento superior y una complejidad moderada.

4.2. Evaluación cuantitativa en el conjunto de prueba

Tras el entrenamiento, los modelos se evaluaron en el conjunto de prueba de 1,000 imágenes, utilizando un umbral de binarización fijo de 0.5 para convertir las probabilidades de salida en máscaras binarias. La Tabla 4.2 presenta las métricas principales de rendimiento, ordenadas por Dice Score descendente. Los valores de Dice e IoU se presentan como media $\pm$ desviación estándar, calculadas sobre las 1,000 imágenes, reflejando tanto el rendimiento promedio como la consistencia del modelo.

Tabla 4.2: Resultados de evaluación en el conjunto de prueba ($n = 1,000$ imágenes)

Modelo	Dice Score	IoU	Precisión	Recall	F1-Score
DeepLabV3+	0,8774 $\pm$ 0,141	0,8022 $\pm$ 0,167	0.8732	0.9182	0.8951
Attention U-Net	0,8658 $\pm$ 0,141	0,7842 $\pm$ 0,170	0.8562	0.9166	0.8854
U-Net Básica	0,8658 $\pm$ 0,138	0,7837 $\pm$ 0,171	0.8606	0.9125	0.8858
TransUNet	0,8638 $\pm$ 0,162	0,7865 $\pm$ 0,187	0.8844	0.8901	0.8872
Residual U-Net	0,8578 $\pm$ 0,147	0,7733 $\pm$ 0,177	0.8632	0.8977	0.8801
U-Net++	0,8552 $\pm$ 0,156	0,7720 $\pm$ 0,186	0.8641	0.8962	0.8799

DeepLabV3+ obtuvo el mejor rendimiento global con un Dice Score de $0,8774 \pm 0,141$, seguido de cerca por Attention U-Net y U-Net Básica (ambos con 0.8658). Es notable que, a pesar de su superioridad en el conjunto de validación durante el entrenamiento, TransUNet (0.8638) no logró superar a las U-Nets clásicas en el conjunto de prueba. Este resultado sugiere una posible sobreoptimización hacia las características específicas del conjunto de entrenamiento o una menor capacidad de generalización a la variabilidad presente en las imágenes de prueba, y que posiblemente no existía en el conjunto de validación al ser de un tamaño mucho menor.




Figura 4.1: Resultados de Dice Score e IoU en el conjunto de prueba

En cuanto al compromiso entre precisión y recall, se observan patrones diferenciados que reflejan la estrategia de segmentación de cada arquitectura. DeepLabV3+ y Attention U-Net muestran un recall más alto (0.9182 y 0.9166 respectivamente), indicando una mejor capacidad para detectar la totalidad de los píxeles de lesión, aunque a costa de una precisión ligeramente menor (más falsos positivos). Este comportamiento es clínicamente valioso en un escenario de cribado, donde es preferible no pasar por alto área maligna. TransUNet, por el contrario, presenta la mayor precisión (0.8844) pero el recall más bajo (0.8901) entre los modelos mejor rankeados. Esto sugiere un comportamiento más conservador, generando menos falsos positivos pero arriesgándose a omitir algunos píxeles de la lesión (falsos negativos). Este perfil podría ser más adecuado para una segunda opinión confirmatoria.

4.3. Análisis estadístico comparativo

Para determinar la significancia estadística de las diferencias observadas en las métricas globales, se realizó un análisis comparativo detallado que consideró no solo los promedios, sino la distribución completa de los valores obtenidos en cada una de las imágenes del conjunto de prueba. La Tabla 4.3 presenta estadísticas descriptivas adicionales de la distribución del Dice Score para cada modelo, ofreciendo una visión más rica de su consistencia y comportamiento en casos extremos.

Tabla 4.3: Estadísticas detalladas de la distribución de Dice Scores por modelo

Modelo	Mediana	P25–P75	Mínimo	Máximo
DeepLabV3+	0.9230	0.871–0.950	0.022	0.996
Attention U-Net	0.9154	0.851–0.943	0.015	0.997
U-Net Básica	0.9154	0.848–0.943	0.012	0.997
TransUNet	0.9194	0.863–0.948	0.010	0.997
Residual U-Net	0.9098	0.841–0.941	0.014	0.996
U-Net++	0.9117	0.843–0.943	0.011	0.997

La mediana del Dice Score, una medida de tendencia central más robusta a valores atípicos que la media, confirma el liderazgo de DeepLabV3+ (0.9230). Esto indica que para más de la mitad de las imágenes, su rendimiento es incluso mejor que lo sugerido por su media. Los rangos intercuartílicos (P25-P75), que abarcan el 50% central de los datos, son similares entre todos los modelos (aproximadamente entre 0.84 y 0.95). Esta similitud sugiere que todas las arquitecturas manejan adecuadamente la mayoría de los casos "típicos". Sin embargo, los valores mínimos (todos por debajo de 0.025) revelan que todos los modelos pueden enfrentar dificultades extremas con algunas imágenes.

4.4. Análisis cualitativo y visualización

Para comprender mejor la naturaleza de los aciertos y errores de los modelos, se realizó un análisis cualitativo que reveló patrones diferenciados en la segmentación de lesiones según la arquitectura del modelo. La Figura 4.2 muestra un análisis comparativo estruc-

turado de tres casos representativos con distintos grados de dificultad, presentando tanto las imágenes originales y sus máscaras de referencia como las predicciones generadas por cada uno de los seis modelos, junto con sus respectivos valores de Dice Score.




Figura 4.2: Comparación cualitativa estructurada de segmentaciones para los seis modelos evaluados. Para cada uno de los tres casos clínicos representativos se muestran: la imagen dermatoscópica original, la máscara de referencia (Ground Truth), y las máscaras segmentadas por U-Net Básica, Attention U-Net, Residual U-Net, U-Net++, DeepLabV3+, y TransUNet. Cada predicción incluye su correspondiente Dice Score, permitiendo una evaluación visual y cuantitativa simultánea.

DeepLabV3+ demostró una habilidad especial para capturar bordes precisos y formas irregulares, produciendo contornos suaves pero detallados. Esto se atribuye probablemente a su módulo ASPP, que captura contexto a múltiples escalas sin perder resolución espacial. En lesiones con bordes difusos, DeepLabV3+ mostró transiciones más naturales entre la lesión y el fondo. TransUNet también mostró segmentaciones consistentes y bien definidas.

Attention U-Net exhibió un desempeño superior en la supresión de artefactos como vellos y burbujas, gracias a sus mecanismos de atención que aprenden a atenuar las características provenientes de regiones irrelevantes del encoder. Sin embargo, en algunos casos

este mismo mecanismo condujo a un suavizado excesivo de los bordes, especialmente en lesiones pequeñas donde los detalles finos podían ser considerados ruidos atenuados.

U-Net++ mostró un buen rendimiento en lesiones pequeñas y medianas, beneficiándose de sus conexiones densas anidadas que facilitan la fusión de características multiescala. Sin embargo, presentó algunas dificultades con lesiones muy grandes o de formas extremadamente irregulares, donde la gran cantidad de conexiones podría estar introduciendo redundancia o dificultando el flujo de información óptimo.

4.5. Curvas ROC y análisis de calibración

Dado que los modelos producen mapas de probabilidad continuos (no solo máscaras binarias), es importante evaluar su capacidad discriminativa a través de todo el rango de umbrales posibles. La Figura 4.3 muestra las curvas ROC (Receiver Operating Characteristic) comparativas para los seis modelos, evaluando su rendimiento en la tarea de clasificación binaria a nivel de píxel.

Todos los modelos mostraron un excelente desempeño discriminativo, con áreas bajo la curva (AUC) superiores a 0.95. DeepLabV3+ obtuvo la AUC más alta (0.982), seguido de TransUNet (0.978) y Attention U-Net (0.975). Las curvas revelan que todos los modelos mantienen altas tasas de verdaderos positivos (sensibilidad) incluso con tasas de falsos positivos muy bajas. Por ejemplo, a una tasa de falsos positivos del 5 %, todos los modelos logran una sensibilidad superior al 90 %.

Esta característica es particularmente valiosa en aplicaciones médicas, donde los falsos positivos (sobrediagnóstico) conllevan costos psicológicos, económicos y clínicos significativos (biopsias innecesarias) y donde se prefiere un sistema conservador que minimice los FP aunque sacrifique algo de sensibilidad. La pendiente pronunciada de las curvas cerca del origen indica que pequeños incrementos en el umbral de clasificación (haciendo al modelo más conservador) reducen drásticamente los falsos positivos con una pérdida relativamente pequeña de sensibilidad.




Figura 4.3: Curvas ROC comparativas para los seis modelos evaluados. El área bajo la curva (AUC) mide la capacidad discriminativa global. Todas las arquitecturas muestran un excelente desempeño ($AUC > 0.95$), con DeepLabV3+ alcanzando el valor más alto.

4.6. Análisis de eficiencia computacional

Más allá de la precisión métrica, la viabilidad práctica de implementar estos modelos en entornos clínicos o de investigación depende críticamente de su eficiencia computacional. La Tabla 4.4 compara los tiempos de inferencia (por imagen) para cada arquitectura, medidos en una RTX 4080 con entrada de tamaño 256×256 y presentados como media $\pm$ desviación estándar calculada sobre 1,000 inferencias del conjunto de prueba.

Tabla 4.4: Análisis de eficiencia computacional en inferencia (tamaño de entrada: 256×256)

Modelo	Tiempo inferencia (ms/img)
U-Net Básica	5.01 ± 1.42
Attention U-Net	6.25 ± 2.39
Residual U-Net	6.42 ± 2.30
U-Net++	6.92 ± 2.73
DeepLabV3+	4.13 ± 2.06
TransUNet	8.57 ± 4.18

DeepLabV3+ demostró la mayor eficiencia en velocidad, con 4.13 ms por imagen (equivalente a aproximadamente 242 imágenes por segundo) y la menor variabilidad temporal. Esta notable eficiencia, combinada con su superior rendimiento métrico, lo posiciona como la opción óptima para aplicaciones que requieren tanto alta precisión como procesamiento en tiempo real. Su velocidad superior se atribuye a su diseño optimizado con convoluciones dilatadas que capturan contexto multiescala de manera computacionalmente eficiente.

U-Net Básica mostró la segunda mejor eficiencia (5.01 ms), aproximadamente un 21 % más lenta que DeepLabV3+ pero significativamente más rápida que sus variantes más complejas. Las arquitecturas con mecanismos adicionales exhibieron penalizaciones de rendimiento predecibles: Attention U-Net (6.25 ms) y Residual U-Net (6.42 ms) mostraron incrementos del 25-28 %, mientras que U-Net++ (6.92 ms) y TransUNet (8.57 ms) presentaron las mayores latencias debido a sus estructuras computacionalmente más costosas.

La variabilidad en los tiempos de inferencia también revela patrones diferenciados: Dee-

pLabV3+ mostró el comportamiento más estable ($\sigma = 2.06$ ms), mientras que TransUNet exhibió la mayor dispersión ($\sigma = 4.18$ ms), sugiriendo que su tiempo de procesamiento es más sensible a las características específicas de cada imagen. Estos resultados confirman que DeepLabV3+ representa el punto óptimo en el compromiso precisión-velocidad, siendo simultáneamente el modelo más preciso y el más eficiente, una combinación particularmente valiosa para implementaciones en entornos clínicos donde tanto la exactitud diagnóstica como la capacidad de procesamiento en tiempo real son críticas.

4.7. Resumen de resultados

En la Tabla 4.5 se presenta un resumen que combina las dimensiones clave de rendimiento métrico, eficiencia computacional y complejidad del modelo. En ella se ve claramente que DeepLabV3+ emerge como el modelo mejor balanceado, con el mejor rendimiento métrico, la mayor velocidad de inferencia y una complejidad paramétrica moderada. Todo esto lo convierte en la elección recomendada para la mayoría de aplicaciones prácticas de segmentación dermatológica donde se busca un equilibrio óptimo.

Tabla 4.5: Resumen de rendimiento y eficiencia para la selección de modelos

Modelo	Dice Score	T. inferencia (ms)	Parámetros (M)
DeepLabV3+	0.8774	4.13	20.3
U-Net Básica	0.8658	5.01	31.0
Attention U-Net	0.8658	6.25	31.4
TransUNet	0.8638	8.57	39.9
Residual U-Net	0.8578	6.42	32.4
U-Net++	0.8552	6.92	9.0

U-Net++ ofrece una alternativa atractiva cuando los recursos de memoria o almacenamiento son muy limitados. Aunque su Dice Score es 0.022 puntos inferior al de DeepLabV3+, requiere menos de la mitad de parámetros y un 10 % menos de memoria GPU, con una velocidad aún respetable. Para escenarios con restricciones extremas de recursos, esta ligera pérdida de precisión podría ser un compromiso aceptable.

Las U-Nets clásicas (Básica, Attention, Residual) muestran un rendimiento muy similar entre sí, pero son superadas en velocidad y eficiencia por DeepLabV3+. Su principal ventaja radica en la madurez, amplia documentación y facilidad de implementación y modificación.

TransUNet, a pesar de su innovador diseño, no justifica su mayor complejidad y consumo de recursos en esta tarea específica, dado que no logra superar significativamente a arquitecturas más eficientes. Podría explorarse más en escenarios con datos mucho más abundantes.

4.8. Demostración de la aplicación web para inferencia y cálculo ABCD

Este apartado presenta una demostración práctica con un ejemplo de uso de la aplicación web desarrollada para inferencia y cálculo de métricas ABCD en tiempo real. La aplicación, disponible como herramienta interactiva, encapsula los principales hallazgos de esta investigación en una interfaz accesible.

4.8.1. Arquitectura y funcionalidades principales

La aplicación web implementa una arquitectura cliente-servidor moderna que permite a los usuarios cargar imágenes dermatoscópicas, ejecutar inferencia con cualquiera de los seis modelos entrenados, visualizar resultados de segmentación en tiempo real y calcular automáticamente las métricas ABCD derivadas de las máscaras segmentadas. La interfaz se organiza en los siguientes módulos funcionales claramente diferenciados:

- **Gestión de pacientes:** Permite crear y administrar registros de pacientes, asociando múltiples análisis a cada individuo para facilitar el seguimiento de lesiones a lo largo del tiempo. Cada registro mantiene un historial completo de todos los análisis realizados.
- **Sistema de carga de imágenes:** Soporta múltiples formatos de imagen (JPG, PNG) mediante interfaz de arrastrar y soltar o selección tradicional, con validación de tipo de archivo y previsualización instantánea de la selección.

- **Selector de modelos:** Ofrece acceso a los seis modelos entrenados en esta investigación (U-Net, Attention U-Net, Residual U-Net, U-Net++, DeepLabV3+, TransUNet), permitiendo comparar resultados entre arquitecturas diferentes.
- **Panel de métricas ABCD:** Calcula y visualiza en tiempo real las cuatro dimensiones del sistema ABCD a partir de la máscara segmentada, proporcionando tanto valores cuantitativos como indicadores cualitativos de riesgo (bajo/medio/alto) codificados por colores.




Figura 4.4: Interfaz de la aplicación web mostrando los módulos de gestión de pacientes, selección de modelo y subida de imagen.

4.8.2. Flujo de trabajo del usuario

El flujo de trabajo simulado implementado en la aplicación sigue una secuencia lógica que replica procesos diagnósticos reales:

1. **Gestión de paciente:** Selección o creación de un registro de paciente para asociar los análisis.
2. **Subida de imagen:** Carga de la imagen dermatoscópica mediante arrastrar y soltar o selección de archivo.
3. **Selección de modelo:** Elección de una de las seis arquitecturas entrenadas.
4. **Inferencia:** Procesamiento automático que genera la máscara de segmentación.

5. **Análisis ABCD:** Cálculo automático de las cuatro métricas dermatoscópicas a partir de la máscara segmentada.
6. **Visualización:** Presentación de resultados incluyendo imagen original, máscara, superposición y panel de métricas con indicadores de riesgo.

4.8.3. Ejemplo práctico de análisis ABCD

La Figura 4.5 ilustra un caso de uso completo donde se analiza una lesión pigmentada atípica utilizando el modelo TransUNet.




Figura 4.5: Ejemplo de análisis ABCD completo. La lesión presenta asimetría moderada (0.28), bordes poco irregulares, 5 colores significativos incluyendo rojo y diámetro de 20.26 mm, resultando en una puntuación de riesgo medio de 4.6/10.

5. Conclusiones y trabajo futuro

Este capítulo sintetiza las principales conclusiones derivadas del estudio comparativo, discute las implicaciones prácticas de los hallazgos, reconoce las limitaciones del trabajo actual y propone direcciones concretas para futuras investigaciones que partan de esta base.

5.1. Conclusiones

DeepLabV3+ se confirma como la arquitectura más efectiva para la segmentación de lesiones dermatoscópicas, logrando tanto la mejor precisión métrica (Dice Score: 0.8774) como la mejor eficiencia computacional (4.13 ms por inferencia). Este resultado rompe con la suposición común de que los modelos más precisos deben ser inherentemente más lentos y complejos, destacando la importancia crítica de evaluar la eficiencia algorítmica junto con la precisión pura en cualquier evaluación comparativa. Su módulo ASPP, demuestra ser particularmente adecuado para manejar la amplia variabilidad en tamaño, forma y textura de las lesiones cutáneas, permitiendo una delineación precisa de bordes sin sacrificar la comprensión semántica global.

Las arquitecturas basadas en U-Net mantienen una competitividad notable, con Attention U-Net y U-Net Básica obteniendo resultados muy similares (Dice Score: 0.8658). Sin embargo, la incorporación de mecanismos de atención en Attention U-Net no produjo una mejora significativa en las métricas globales en este contexto, lo que sugiere que los beneficios de la atención pueden ser más situacionales que universales en este dominio.

TransUNet, a pesar de su complejidad arquitectónica y capacidad teórica para modelar dependencias de largo alcance, no superó a las arquitecturas más establecidas en este dominio específico. Su rendimiento (Dice Score: 0.8638) sugiere que la integración de Transformers puede no ofrecer ventajas decisivas en tareas de segmentación dermatológica donde el contexto local y la resolución espacial son primordiales y donde el tamaño de los conjuntos de datos puede ser insuficiente para explotar su gran capacidad representacional.

U-Net++ destaca por su eficiencia paramétrica, logrando un rendimiento cercano a las

U-Nets clásicas con solo 9.0 millones de parámetros (aproximadamente un tercio). Esta característica lo hace especialmente atractivo para implementaciones en entornos con recursos computacionales limitados (dispositivos edge, móviles) o cuando el despliegue de modelos muy grandes es problemático.

En cuanto al compromiso entre precisión y recall, se identificaron perfiles distintos. DeepLabV3+ y Attention U-Net priorizan el recall (0.9182 y 0.9166, respectivamente), siendo más sensibles a costa de una precisión ligeramente menor, lo que se traduce en una mayor tasa de falsos positivos. Este perfil es particularmente valioso en escenarios de cribado inicial, donde es crítico no pasar por alto ninguna área potencialmente maligna. En contraste, TransUNet muestra el patrón opuesto, con una mayor precisión (0.8844) pero un recall más bajo (0.8901), adoptando un enfoque más conservador. Este perfil podría preferirse en un entorno de segunda opinión o confirmación diagnóstica, donde el objetivo principal es minimizar las intervenciones o biopsias innecesarias.

5.2. Limitaciones del estudio

A pesar del rigor metodológico aplicado, es importante reconocer las limitaciones inherentes de este trabajo, las cuales contextualizan los resultados y señalan áreas para mejora futura.

Una limitación importante es el conjunto de datos, que, aunque es un benchmark estándar reconocido, presenta un tamaño limitado que puede ser insuficiente para explorar completamente el potencial de arquitecturas complejas y muy parametrizadas como TransUNet, que generalmente requieren volúmenes de datos mucho mayores para estabilizarse y generalizar adecuadamente. Además, el conjunto presenta sesgos conocidos en cuanto a tipos de piel, con una sobrerrepresentación de fototipos claros, y procedencia geográfica, lo que puede limitar severamente la generalización de los modelos entrenados a poblaciones diversas y no representadas.

Otra limitación significativa es la evaluación en un solo dominio modal. Todos los modelos fueron evaluados exclusivamente en imágenes dermatoscópicas adquiridas con equipos

específicos. Su rendimiento, y posiblemente el ranking relativo entre ellos, podría ser significativamente diferente en otras modalidades de imagen dermatológica de uso común, como la fotografía clínica macro (a simple vista) o la microscopía confocal. La generalización del rendimiento a través de modalidades queda por determinar.

La metodología de evaluación también presenta una limitación técnica al emplear un umbral de binarización fijo de 0.5 para todas las imágenes y modelos. En la práctica clínica, umbrales adaptativos que varíen según características de la imagen individual, como el tamaño de la lesión, el contraste o la confianza interna del modelo, podrían optimizar el compromiso entre sensibilidad y especificidad para casos concretos, mejorando potencialmente las métricas prácticas de utilidad clínica.

5.3. Trabajo futuro

Basado en los hallazgos, conclusiones y limitaciones identificadas, se proponen las siguientes direcciones prioritarias para investigación futura, estructuradas en dos áreas principales.

5.3.1. Mejoras metodológicas y técnicas

La mejora metodológica debe centrarse en superar las limitaciones actuales de los datos y los modelos. Un eje fundamental es el entrenamiento con conjuntos más extensos y diversos. Futuros trabajos deberían utilizar y crear conjuntos combinados de mayor volumen o datos institucionales anonimizados, con el objetivo explícito de aumentar la diversidad demográfica. Esto es crucial no solo para mejorar la generalización, sino también para garantizar la equidad algorítmica.

Técnicamente, resulta prometedora la aplicación de Búsqueda Arquitectónica Neural (NAS) especializada. En lugar de limitarse a evaluar arquitecturas diseñadas manualmente para dominios generales, aplicar técnicas de NAS para descubrir automáticamente topologías de segmentación optimizadas específicamente para las peculiaridades del dominio dermatológico podría generar diseños más eficientes y efectivos que los evaluados en este estudio.

Por último, se propone desarrollar modelos probabilísticos y con múltiples umbrales. Estos sistemas irían más allá de producir una simple máscara binaria, generando también un mapa de incertidumbre, mediante técnicas como Deep Learning Bayesiano o ensembles de modelos.

5.3.2. Extensiones clínicas y de aplicación

Una extensión natural y de gran relevancia clínica es la segmentación de subestructuras dermatoscópicas. El paso siguiente es pasar de segmentar el contorno completo de la lesión a identificar y delimitar automáticamente estructuras internas específicas y diagnósticamente relevantes: redes pigmentadas, glóbulos, estrías radiales, áreas de regresión (velo azul-blanco), etc. Esto proporcionaría una cuantificación objetiva directa de los criterios ABCD (Asimetría, Bordes, Color, Diámetro y estructuras) y un nivel de detalle invaluable para el seguimiento temporal.

Para facilitar la adopción clínica, también es imperativo incorporar sistemas de Explicabilidad (XAI) integrada. Estas técnicas deben generar explicaciones visuales, como mapas que destaquen las regiones de la imagen más influyentes en la decisión de segmentación, o explicaciones textuales que enumeren las características dermatoscópicas observadas que llevaron a la delineación propuesta. La transparencia es fundamental para aumentar la confianza del clínico. Además, la validación última debe provenir de estudios prospectivos y de impacto rigurosamente diseñados. Se necesitan estudios clínicos controlados que evalúen el impacto real de integrar estas herramientas en la rutina asistencial.

Referencias

- Adamson, A. S., y Smith, A. (2020). Machine learning and health care disparities in dermatology. *JAMA Dermatology*, 154(11), 1247–1248. doi: 10.1001/jamadermatol.2020.2349
- Argenziano, G., Soyer, H. P., Chimenti, S., Talamini, R., Corona, R., Sera, F., . . . Kopf, A. W. (2003). Dermoscopy of pigmented skin lesions: Results of a consensus meeting via the internet. *Journal of the American Academy of Dermatology*, 48(5), 679–693. doi: 10.1067/mjd.2003.281
- Arnold, M., Singh, D., Laversanne, M., Vignat, J., Vaccarella, S., Meheus, F., . . . Bray, F. (2022). Global burden of cutaneous melanoma in 2020 and projections to 2040. *JAMA Dermatology*, 158(5), 495–503. doi: 10.1001/jamadermatol.2022.0160
- Barata, C., Celebi, M. E., y Marques, J. S. (2019). A survey of feature extraction in dermoscopy image analysis of skin cancer. *IEEE Journal of Biomedical and Health Informatics*, 23(3), 1096–1109. doi: 10.1109/JBHI.2018.2845939
- Buslaev, A., Iglovikov, V. I., Khvedchenya, E., Parinov, A., Druzhinin, M., y Kalinin, A. A. (2020). Albumentations: Fast and flexible image augmentations. *Information*, 11(2), 125. doi: 10.3390/info11020125
- Celebi, M. E., Kingravi, H. A., Uddin, B., Iyatomi, H., Aslandogan, Y. A., Stoecker, W. V., y Moss, R. H. (2007). A methodological approach to the classification of dermoscopy images. *Computerized Medical Imaging and Graphics*, 31(6), 362–373. doi: 10.1016/j.compmedimag.2007.01.003
- Chen, J., Lu, Y., Yu, Q., Luo, X., Adeli, E., Wang, Y., . . . Zhou, Y. (2021). Transunet: Transformers make strong encoders for medical image segmentation. *arXiv preprint arXiv:2102.04306*.
- Chen, L.-C., Zhu, Y., Papandreou, G., Schroff, F., y Adam, H. (2018). Encoder-decoder with atrous separable convolution for semantic image segmentation. En *Proceedings of the european conference on computer vision (eccv)* (pp. 801–818). doi: 10.1007/978-3-030-01234-2_49
- Clawson, K. M., Morrow, P. J., Scotney, B. W., McKenna, D. B., y Dolan, O. M. (2009). Determination of optimal axes for skin lesion asymmetry quantification. En *2009 IEEE international conference on image processing* (pp. 437–440). doi: 10.1109/ICIP.2009.5413937

- Codella, N. C., Gutman, D., Celebi, M. E., Helba, B., Marchetti, M. A., Dusza, S. W., ... Halpern, A. (2018). Skin lesion analysis toward melanoma detection: A challenge at the 2017 international symposium on biomedical imaging (isbi), hosted by the international skin imaging collaboration (isic). En *2018 IEEE 15th International Symposium on Biomedical Imaging (ISBI 2018)* (pp. 168–172). doi: 10.1109/ISBI.2018.8363547
- Dice, L. R. (1945). Measures of the amount of ecologic association between species. *Ecology*, 26(3), 297–302. doi: 10.2307/1932409
- Esteva, A., Kuprel, B., Novoa, R. A., Ko, J., Swetter, S. M., Blau, H. M., y Thrun, S. (2017). Dermatologist-level classification of skin cancer with deep neural networks. *Nature*, 542(7639), 115–118. doi: 10.1038/nature21056
- Friedman, R. J., Rigel, D. S., y Kopf, A. W. (1985). Early detection of malignant melanoma: The role of physician examination and self-examination of the skin. *CA: A Cancer Journal for Clinicians*, 35(3), 130–151. doi: 10.3322/canjclin.35.3.130
- Gershenwald, J. E., Scolyer, R. A., Hess, K. R., Sondak, V. K., Long, G. V., Ross, M. I., ... Thompson, J. F. (2017). Melanoma staging: Evidence-based changes in the american joint committee on cancer eighth edition cancer staging manual. *CA: A Cancer Journal for Clinicians*, 67(6), 472–492. doi: 10.3322/caac.21409
- González-Díaz, I. (2017). Dermaknet: Incorporating the knowledge of dermatologists to convolutional neural networks for skin lesion diagnosis. *IEEE Journal of Biomedical and Health Informatics*, 23(2), 547–559. doi: 10.1109/JBHI.2017.2785765
- He, K., Zhang, X., Ren, S., y Sun, J. (2016). Deep residual learning for image recognition. En *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 770–778). doi: 10.1109/CVPR.2016.90
- Isensee, F., Jaeger, P. F., Kohl, S. A. A., Petersen, J., y Maier-Hein, K. H. (2021). nnu-net: A self-configuring method for deep learning-based biomedical image segmentation. *Nature Methods*, 18(2), 203–211. doi: 10.1038/s41592-020-01008-z
- Jaccard, P. (1912). The distribution of the flora in the alpine zone. *New Phytologist*, 11(2), 37–50. doi: 10.1111/j.1469-8137.1912.tb05611.x
- Jafari, M. H., Nasr-Esfahani, E., Karimi, N., Soroushmehr, S. M. R., Samavi, S., y Najarian, K. (2020). Extraction of skin lesions from non-dermoscopic images using deep learning. *Artificial Intelligence in Medicine*, 103, 101789. doi: 10.1016/j.artmed.2020.101789
- Kittler, H., Pehamberger, H., Wolff, K., y Binder, M. (2002). Diagnostic accuracy of

- dermoscopy. *The Lancet Oncology*, 3(3), 159–165. doi: 10.1016/S1470-2045(02)00679-4
- Krizhevsky, A., Sutskever, I., y Hinton, G. E. (2012). Imagenet classification with deep convolutional neural networks. En *Advances in neural information processing systems* (Vol. 25, pp. 1097–1105).
- Litjens, G., Kooi, T., Bejnordi, B. E., Setio, A. A. A., Ciompi, F., Ghafoorian, M., ... Sánchez, C. I. (2017). A survey on deep learning in medical image analysis. *Medical Image Analysis*, 42, 60–88. doi: 10.1016/j.media.2017.07.005
- Liu, L., Mou, L., Zhu, X. X., y Mandal, M. (2020). Automatic skin lesion classification based on mid-level feature learning. *Computerized Medical Imaging and Graphics*, 84, 101765. doi: 10.1016/j.compmedimag.2020.101765
- Loshchilov, I., y Hutter, F. (2017). Decoupled weight decay regularization. *arXiv preprint arXiv:1711.05101*.
- Marchetti, M. A., Codella, N. C., Dusza, S. W., Gutman, D. A., Helba, B., Kalloo, A., ... Halpern, A. C. (2020). Results of the 2016 international skin imaging collaboration international symposium on biomedical imaging challenge: Comparison of the accuracy of computer algorithms to dermatologists for the diagnosis of melanoma from dermoscopic images. *Journal of the American Academy of Dermatology*, 82(3), 622–627. doi: 10.1016/j.jaad.2019.07.016
- Menzies, S. W. (2009). Evidence-based dermoscopy. *Dermatologic Clinics*, 27(3), 391–400. doi: 10.1016/j.det.2009.05.004
- Menzies, S. W., Ingvar, C., Crotty, K. A., y McCarthy, W. H. (1996). Frequency and morphologic characteristics of invasive melanomas lacking specific surface microscopic features. *Archives of Dermatology*, 132(10), 1178–1182. doi: 10.1001/archderm.1996.03890340044007
- Milletari, F., Navab, N., y Ahmadi, S.-A. (2016). V-net: Fully convolutional neural networks for volumetric medical image segmentation. En *2016 fourth international conference on 3d vision (3dv)* (pp. 565–571). doi: 10.1109/3DV.2016.79
- Nachbar, F., Stolz, W., Merkle, T., Cognetta, A. B., Vogt, T., Landthaler, M., ... Plewig, G. (1994). The abcd rule of dermoscopy: High prospective value in the diagnosis of doubtful melanocytic skin lesions. *Journal of the American Academy of Dermatology*, 30(4), 551–559. doi: 10.1016/S0190-9622(94)70061-3
- Navarrete-Dechent, C., Dusza, S. W., Liopyris, K., Marghoob, A. A., Halpern, A. C., y

- Marchetti, M. A. (2021). Automated dermatological diagnosis: Hype or reality? *Journal of Investigative Dermatology*, 141(5), 1163–1169. doi: 10.1016/j.jid.2020.11.032
- Oktay, O., Schlemper, J., Le Folgoc, L., Lee, M., Heinrich, M., Misawa, K., . . . Rueckert, D. (2018). Attention u-net: Learning where to look for the pancreas. *arXiv preprint arXiv:1804.03999*.
- Oliveira, R. B., Mercedes Filho, E., Ma, Z., Papa, J. P., Pereira, A. S., y Tavares, J. M. R. S. (2016). Computational methods for the image segmentation of pigmented skin lesions: A review. *Computer Methods and Programs in Biomedicine*, 131, 127–141. doi: 10.1016/j.cmpb.2016.03.032
- Powers, D. M. W. (2020). Evaluation: From precision, recall and f-measure to roc, informedness, markedness and correlation. *Journal of Machine Learning Technologies*, 2(1), 37–63.
- Prechelt, L. (1998). Early stopping—but when? En *Neural networks: Tricks of the trade* (pp. 55–69). Springer. doi: 10.1007/3-540-49430-8_3
- Reis, H. C., Turk, V., Khoshelham, K., y Kaya, S. (2021). Explainable deep learning for medical image analysis: A survey. *Computer Methods and Programs in Biomedicine*, 213, 106535. doi: 10.1016/j.cmpb.2021.106535
- Ronneberger, O., Fischer, P., y Brox, T. (2015). U-net: Convolutional networks for biomedical image segmentation. En *International conference on medical image computing and computer-assisted intervention* (pp. 234–241). doi: 10.1007/978-3-319-24574-4_28
- Salehi, S. S. M., Erdogmus, D., y Gholipour, A. (2017). Tversky loss function for image segmentation using 3d fully convolutional deep networks. En *International workshop on machine learning in medical imaging* (pp. 379–387). doi: 10.1007/978-3-319-67389-9_44
- Schadendorf, D., van Akkooi, A. C. J., Berking, C., Griewank, K. G., Gutzmer, R., Hauschild, A., . . . Ugurel, S. (2018). Melanoma. *The Lancet*, 392(10151), 971–984.
- Sørensen, T. (1948). A method of establishing groups of equal amplitude in plant sociology based on similarity of species and its application to analyses of the vegetation on danish commons. *Kongelige Danske Videnskabernes Selskab*, 5(4), 1–34.
- Tschandl, P., Rinner, C., Apalla, Z., Argenziano, G., Codella, N., Halpern, A., . . . Kittler, H. (2020). Human-computer collaboration for skin cancer recognition. *Nature*

- Medicine*, 26(8), 1229–1234. doi: 10.1038/s41591-020-0942-0
- Tschandl, P., Rosendahl, C., y Kittler, H. (2018). The ham10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions. *Scientific Data*, 5(1), 1–9. doi: 10.1038/sdata.2018.161
- Vestergaard, M. E., Macaskill, P., Holt, P. E., y Menzies, S. W. (2010). Dermoscopy compared with naked eye examination for the diagnosis of primary melanoma: A meta-analysis of studies performed in a clinical setting. *British Journal of Dermatology*, 163(3), 669–676. doi: 10.1111/j.1365-2133.2010.09947.x
- Yang, J., Xie, F., Fan, H., Jiang, Z., y Liu, J. (2019). Classification for dermoscopy images using convolutional neural networks based on the ensemble of individual net and group decision making. *IEEE Access*, 7, 110933–110945. doi: 10.1109/ACCESS.2019.2934261
- Young, A. T., Xiong, M., Pfau, J., Keiser, M. J., y Wei, M. L. (2020). Artificial intelligence in dermatology: A primer. *Journal of Investigative Dermatology*, 140(8), 1504–1512. doi: 10.1016/j.jid.2020.02.026
- Yuan, Y., Chao, M., y Lo, Y.-C. (2020). Automatic skin lesion segmentation using deep fully convolutional networks with jaccard distance. *IEEE Transactions on Medical Imaging*, 36(9), 1876–1886. doi: 10.1109/TMI.2017.2695227
- Zhang, Z., Liu, Q., y Wang, Y. (2018). Road extraction by deep residual u-net. *IEEE Geoscience and Remote Sensing Letters*, 15(5), 749–753. doi: 10.1109/LGRS.2018.2802944
- Zhou, Z., Siddiquee, M. M. R., Tajbakhsh, N., y Liang, J. (2018). Unet++: A nested u-net architecture for medical image segmentation. En *Deep learning in medical image analysis and multimodal learning for clinical decision support* (pp. 3–11). doi: 10.1007/978-3-030-00889-5_1

A. Resumen del código

Este apéndice describe la organización del repositorio del proyecto, los requisitos de instalación y las instrucciones para reproducir los experimentos.

A.1. Requisitos del sistema

A.1.1. Prerrequisitos

- Python 3.9 o superior
- Conda (Anaconda o Miniconda)
- Git LFS (para descargar los modelos entrenados)
- GPU NVIDIA con soporte CUDA (recomendado)

A.1.2. Instalación del entorno

```
1 # Instalar Git LFS y clonar el repositorio
2 git lfs install
3 git clone https://github.com/salvalago23/tfe_salvador_perez_lago.
   git
4 cd tfe_salvador_perez_lago
5
6 # Crear y activar el entorno conda
7 conda env create -f environment.yml
8 conda activate tfm_segmentacion_env
9
10 # Descargar el dataset ISIC 2018
11 python download_dataset.py
```

Listing A.1: Instalación del proyecto

A.1.3. Dataset ISIC 2018

El script `download_dataset.py` descarga automáticamente el dataset completo del ISIC 2018 Challenge (Task 1: Lesion Boundary Segmentation). El dataset ocupa aproximadamente 13 GB y contiene:

Tabla A.1: Contenido del dataset ISIC 2018

Conjunto	Imágenes	Tamaño
Training Input	2,594	10.46 GB
Training GroundTruth	2,594	33 MB
Validation Input	100	228 MB
Validation GroundTruth	100	1 MB
Test Input	1,000	2.26 GB
Test GroundTruth	1,000	11 MB

A.2. Estructura de directorios

```

1 tfe_salvador_perez_lago/
2 |-- README.md                # Documentacion principal
3 |-- environment.yml           # Dependencias del entorno conda
4 |-- download_dataset.py       # Script de descarga del dataset
5 |-- app/                      # Aplicacion web de segmentacion
6 |   |-- README.md             # Documentacion de la app
7 |   |-- run.sh                 # Script de ejecucion del
    servidor
8 |   |-- backend/              # Backend FastAPI
9 |   |   |-- main.py           # Servidor con API REST
10 |   |   |-- clinical_analysis/ # Analisis clinico ABCD
11 |   |   +-- data/             # Base de datos y resultados
12 |   +-- frontend/            # Interfaz web
13 |       +-- index.html        # SPA con visualizacion
14 |-- data/                    # Datos del proyecto
15 |   |-- raw/                  # Datos originales ISIC 2018
16 |   |   |-- isic_2018_train/   # 2594 imagenes + mascaras
17 |   |   |-- isic_2018_val/     # 100 imagenes + mascaras
18 |   |   +-- isic_2018_test/    # 1000 imagenes + mascaras
19 |   +-- processed/            # Datos preprocesados (.npz)
20 |       |-- train/
21 |       |-- val/
22 |       +-- test/
23 |-- notebooks/                # Jupyter Notebooks

```



```
24 | |-- 01_eda.ipynb                # Analisis exploratorio
25 | |-- 02_model_train.ipynb        # Entrenamiento de modelos
26 | |-- 03_model_eval.ipynb        # Evaluacion y comparacion
27 | +-- experiments/                # Resultados experimentales
28 |     |-- eda_results/            # Estadisticas del dataset
29 |     |-- notebook_experiments/   # Modelos entrenados
30 |         |-- u-net_basica/
31 |         |-- attention_u-net/
32 |         |-- residual_u-net/
33 |         |-- u-net++/
34 |         |-- deeplabv3+/
35 |         +-- transunet/
36 |     +-- comparative_analysis/    # Comparacion de rendimiento
37 +-- src/                          #Codigo fuente modular
38     |-- data_preparation/         # Gestion de datos
39     |   |-- data_loader.py        # DataLoader con balanceo
40     |   +-- dataset.py            # Dataset ISIC con augmentacion
41     +-- models/                   # Arquitecturas de segmentacion
42         |-- __init__.py
43         |-- unet.py                # U-Net basica
44         |-- attention_unet.py      # U-Net con atencion
45         |-- residual_unet.py       # U-Net con bloques residuales
46         |-- unet_plusplus.py       # U-Net++ (nested U-Net)
47         |-- deeplabv3plus.py       # DeepLabV3+
48         |-- transunet.py           # TransUNet
49         |-- losses.py              # Funciones de perdida
50     +-- metrics.py                # Metricas de evaluacion
```

Listing A.2: Estructura del proyecto

A.3. Descripción de componentes principales

A.3.1. Módulo de datos (src/data_preparation/)

dataset.py

Implementa la clase `ISIC2018Dataset` con las siguientes características:

- Carga de imágenes en formato raw (.jpg/.png) o preprocesadas (.npy)
- Aumentación en tiempo real usando la biblioteca Albumentations
- Normalización con estadísticas específicas del dataset ISIC
- Manejo de casos edge (imágenes corruptas, máscaras faltantes)

`data_loader.py`

Clase `ISICDataLoader` que gestiona:

- Creación de datasets para conjuntos train/val/test
- Balanceo de clases mediante `WeightedRandomSampler`
- Configuración optimizada de DataLoaders (`num_workers`, `pin_memory`)

A.3.2. Módulo de modelos (`src/models/`)

Implementaciones de las seis arquitecturas de segmentación:

- **U-Net básica** (`unet.py`)
- **Attention U-Net** (`attention_unet.py`)
- **Residual U-Net** (`residual_unet.py`)
- **U-Net++** (`unet_plusplus.py`)
- **DeepLabV3+** (`deeplabv3plus.py`)
- **TransUNet** (`transunet.py`)

Módulos auxiliares:

- `losses.py`: DiceLoss, CombinedLoss (BCE + Dice), IoULoss
- `metrics.py`: Dice Score, IoU, Precision, Recall, F1-Score

A.3.3. Notebooks experimentales (notebooks/)

- `01_eda.ipynb`: Análisis exploratorio de datos (distribuciones de tamaño, estadísticas de intensidad, análisis de máscaras)
- `02_model_train.ipynb`: Experimentación con hiperparámetros y entrenamiento de las seis arquitecturas
- `03_model_eval.ipynb`: Comparación cuantitativa y cualitativa de modelos, generación de figuras y tablas

Los modelos entrenados se guardan en `notebooks/experiments/notebook_experiments/`, con cada modelo conteniendo:

- `best_model.pth`: Checkpoint del mejor modelo (según Dice en validación)
- `training_history.json`: Métricas por época
- Configuración de hiperparámetros utilizada

A.4. Reproducción de experimentos

Para reproducir los experimentos del trabajo:

1. Ejecutar el notebook `01_eda.ipynb` para generar las estadísticas del dataset
2. Ejecutar el notebook `02_model_train.ipynb` para entrenar los seis modelos (requiere GPU)
3. Ejecutar el notebook `03_model_eval.ipynb` para realizar el cálculo de métricas comparativas y figuras

B. Manual de usuario de la app

Este apéndice proporciona instrucciones detalladas para la instalación, configuración y uso de la aplicación web de segmentación de lesiones cutáneas.

B.1. Instalación y ejecución

B.1.1. Requisitos

- Entorno conda del proyecto activado (`tfm_segmentacion_env`)
- Modelos entrenados disponibles en `notebooks/experiments/notebook_experiments/`
- Puerto 8000 disponible

B.1.2. Ejecución del servidor

```
1 # Desde el directorio raiz del proyecto
2 cd app
3
4 # Dar permisos de ejecucion al script (solo la primera vez)
5 chmod +x run.sh
6
7 # Ejecutar el servidor
8 ./run.sh
```

Listing B.1: Ejecución de la aplicación web

Una vez ejecutado, abrir un navegador en `http://localhost:8000`.

B.1.3. Script de ejecución

El script `run.sh` configura automáticamente el entorno:

```
1 #!/bin/bash
2 # Script para ejecutar la aplicacion web
3
4 SCRIPT_DIR="$(cd "$(dirname "${BASH_SOURCE[0]}")" && pwd)"
5 PROJECT_ROOT="$(dirname "$SCRIPT_DIR")"
6
```

```
7 # Configurar PYTHONPATH para importar módulos del proyecto
8 export PYTHONPATH="$PROJECT_ROOT:$PYTHONPATH"
9
10 # Ejecutar servidor FastAPI con uvicorn
11 cd "$SCRIPT_DIR/backend"
12 python -m uvicorn main:app --host 0.0.0.0 --port 8000 --reload
```

Listing B.2: Contenido de run.sh

B.2. API REST

La aplicación expone los siguientes endpoints:

B.2.1. Endpoints de salud e información del sistema

- GET /api/health: Verificación del estado del sistema y dispositivo (CPU/GPU)
- GET /api/models: Lista de modelos de segmentación disponibles

B.2.2. Endpoints de gestión de pacientes

- POST /api/patients: Crear nuevo paciente
- GET /api/patients: Listar todos los pacientes
- GET /api/patients/{id}: Obtener detalles de un paciente
- DELETE /api/patients/{id}: Eliminar paciente y su historial
- GET /api/patients/{id}/results: Obtener historial de análisis del paciente

B.2.3. Endpoint de predicción

- POST /api/predict: Ejecutar segmentación en imagen cargada
 - Parámetros: `file` (imagen), `model` (clave del modelo), `patient_id`
 - Respuesta: Imagen original, máscara de segmentación, superposición, tiempo de inferencia, cobertura de la lesión, métricas ABCD

B.3. Flujo de trabajo del usuario

B.3.1. Paso 1: Gestión de pacientes

Al acceder a la aplicación, el usuario debe seleccionar o crear un paciente:

1. Hacer clic en “Nuevo Paciente” para crear un registro
2. Introducir nombre y notas opcionales
3. Seleccionar el paciente creado de la lista para activarlo

B.3.2. Paso 2: Subida de imagen

La aplicación soporta múltiples métodos de carga:

- **Arrastrar y soltar:** Arrastrar la imagen dermatoscópica sobre la zona de carga
- **Click:** Hacer clic en la zona de carga para abrir el selector de archivos
- **Formatos soportados:** JPG, PNG

B.3.3. Paso 3: Selección de modelo

Seleccionar uno de los seis modelos disponibles del menú desplegable.

B.3.4. Paso 4: Análisis

Hacer clic en “Analizar” para ejecutar:

1. Preprocesamiento de la imagen (resize a 256×256 , normalización)
2. Inferencia del modelo seleccionado
3. Cálculo automático de métricas ABCD
4. Generación de visualizaciones

B.3.5. Paso 5: Visualización de resultados

Los resultados se presentan en un panel organizado:

- **Visualizaciones:** Imagen original, máscara binaria, superposición con transparencia

- **Métricas de rendimiento:** Tiempo de inferencia, cobertura de la lesión
- **Análisis ABCD:** Desglose por componente con niveles de riesgo
- **Puntuación global:** Indicador visual de riesgo (bajo/medio/alto)

B.3.6. Paso 6: Historial

Cada análisis se almacena automáticamente en el historial del paciente:

- Acceso a análisis anteriores desde el panel lateral
- Comparación de evolución temporal de lesiones
- Exportación de resultados (imagen + métricas)

B.4. Estructura de la aplicación

```
1 app/  
2 |-- README.md           # Documentacion de la aplicacion  
3 |-- run.sh              # Script de ejecucion del servidor  
4 |-- backend/  
5 |   |-- main.py         # Servidor principal con API REST  
6 |   |-- clinical_analysis/ # Modulo de analisis clinico  
7 |   |   |-- __init__.py  
8 |   |   +-- abcd_analyzer.py # Analizador de criterios ABCD  
9 |   +-- data/            # Datos persistentes  
10 |       |-- patients.json # Base de datos de pacientes  
11 |       +-- results/     # Resultados de analisis guardados  
12 +-- frontend/           # Interfaz de usuario  
13     +-- index.html       # Aplicacion web de pagina unica
```

Listing B.3: Estructura del directorio app/